Библиотеки Python для Data Science: продолжение

Курсовой проект

Соковнин Игорь Леонидович

Постановка задачи

In [1]:
```
#3.3. Box plot, или ящик с усами
#https://ru.coursera.org/lecture/vvedeniye-dannyye/3-4-diaghramma-rassieianiia-DW6HN
```

Задача

Требуется, на основании имеющихся данных о клиентах банка, построить модель, используя обучающий датасет, для прогнозирования невыполнения долговых обязательств по текущему кредиту. Выполнить прогноз для примеров из тестового датасета.

Наименование файлов с данными

course_project_train.csv - обучающий датасет
course_project_test.csv - тестовый датасет

Целевая переменная

Credit Default - факт невыполнения кредитных обязательств

Метрика качества

F1-score (sklearn.metrics.f1_score)

Требования к решению

Целевая метрика

- F1 > 0.5
- Метрика оценивается по качеству прогноза для главного класса (1 - просрочка по кредиту)

Решение должно содержать

1. Тетрадка Jupyter Notebook с кодом Вашего решения, названная по образцу {ФИО}_solution.ipynb, пример SShirkin_solution.ipynb
2. Файл CSV с прогнозами целевой переменной для тестового датасета, названный по образцу {ФИО}_predictions.csv, пример SShirkin_predictions.csv

Рекомендации для файла с кодом (ipynb)

1. Файл должен содержать заголовки и комментарии (markdown)
2. Повторяющиеся операции лучше оформлять в виде функций
3. Не делать вывод большого количества строк таблиц (5-10 достаточно)
4. По возможности добавлять графики, описывающие данные (около 3-5)
5. Добавлять только лучшую модель, то есть не включать в код все варианты решения проекта
6. Скрипт проекта должен отрабатывать от начала и до конца (от загрузки данных до выгрузки предсказаний)
7. Весь проект должен быть в одном скрипте (файл ipynb).

8. Допускается применение библиотек Python и моделей машинного обучения, которые были в данном курсе.

Сроки сдачи

Сдать проект нужно в течение 5 дней после окончания последнего вебинара. Оценки работ, сданных до дедлайна, будут представлены в виде рейтинга, ранжированного по заданной метрике качества. Проекты, сданные после дедлайна или сданные повторно, не попадают в рейтинг, но можно будет узнать результат.

Этапы выполнения курсового проекта

Построение модели классификации

1. Описание данных
2. Загрузка данных
3. Обзор обучающего датасета +
4. Обработка выбросов +
5. Обработка пропусков +
6. Анализ данных
7. Отбор признаков
8. Балансировка классов
9. Подбор моделей, получение бейзлана
10. Выбор наилучшей модели, настройка гиперпараметров
11. Проверка качества, борьба с переобучением
12. Интерпретация результатов

Прогнозирование на тестовом датасете

1. Выполнить для тестового датасета те же этапы обработки и построниняния признаков
2. Спрогнозировать целевую переменную, используя модель, построенную на обучающем датасете
3. Прогнозы должны быть для всех примеров из тестового датасета (для всех строк)
4. Соблюдать исходный порядок примеров из тестового датасета

Подключение библиотек и скриптов

B [2]:
```
import numpy as np
import pandas as pd
import matplotlib
#import matplotlib.image as img
import matplotlib.pyplot as plt
import seaborn as sns

%matplotlib inline

import warnings
warnings.filterwarnings('ignore')

matplotlib.rcParams.update({'font.size': 14})
```

Построение модели классификации

Описание датасета

- **1. Home Ownership** - домовладение
- **2. Annual Income** - годовой доход
- **3. Years in current job** - количество лет на текущем месте работы
- **4. Tax Liens** - налоговые обременения
- **5. Number of Open Accounts** - количество открытых счетов
- **6. Years of Credit History** - количество лет кредитной истории
- **7. Maximum Open Credit** - наибольший открытый кредит
- **8. Number of Credit Problems** - количество проблем с кредитом
- **9. Months since last delinquent** - количество месяцев с последней просрочки платежа
- **10. Bankruptcies** - банкротства
- **11. Purpose** - цель кредита
- **12. Term** - срок кредита
- **13. Current Loan Amount** - текущая сумма кредита
- **14. Current Credit Balance** - текущий кредитный баланс
- **15. Monthly Debt** - ежемесячный долг
- **16. Credit Score** - Кредитный рейтинг?
- **17. Credit Default** - факт невыполнения кредитных обязательств (0 - погашен вовремя, 1 - просрочка)

Пути к директориям и файлам

B [3]:
```
# input
TRAIN_DATASET_PATH = './course_project/course_project_train.csv'
TEST_DATASET_PATH = './course_project/course_project_test.csv'

# output
PREP_DATASET_PATH = './training_project/training_project_data_prep.csv'
```

Загрузка данных

B [4]:
```
df_train = pd.read_csv(TRAIN_DATASET_PATH)
df_train.head()
```

Out[4]:

	Home Ownership	Annual Income	Years in current job	Tax Liens	Number of Open Accounts	Years of Credit History	Maximum Open Credit	Number of Credit Problems	Months since last delinquent	Bankruptcies	
0	Own Home	482087.0	NaN	0.0	11.0	26.3	685960.0	1.0	NaN	1.0	cor
1	Own Home	1025487.0	10+ years	0.0	15.0	15.3	1181730.0	0.0	NaN	0.0	cor
2	Home Mortgage	751412.0	8 years	0.0	11.0	35.0	1182434.0	0.0	NaN	0.0	cor
3	Own Home	805068.0	6 years	0.0	8.0	22.5	147400.0	1.0	NaN	1.0	cor
4	Rent	776264.0	8 years	0.0	13.0	13.6	385836.0	1.0	NaN	0.0	cor

В [5]:
```
df_test = pd.read_csv(TEST_DATASET_PATH)
df_test.head()
```

Out[5]:

	Home Ownership	Annual Income	Years in current job	Tax Liens	Number of Open Accounts	Years of Credit History	Maximum Open Credit	Number of Credit Problems	Months since last delinquent	Bankruptcies	
0	Rent	NaN	4 years	0.0	9.0	12.5	220968.0	0.0	70.0	0.0	co
1	Rent	231838.0	1 year	0.0	6.0	32.7	55946.0	0.0	8.0	0.0	e
2	Home Mortgage	1152540.0	3 years	0.0	10.0	13.7	204600.0	0.0	NaN	0.0	co
3	Home Mortgage	1220313.0	10+ years	0.0	16.0	17.0	456302.0	0.0	70.0	0.0	co
4	Home Mortgage	2340952.0	6 years	0.0	11.0	23.6	1207272.0	0.0	NaN	0.0	co

В [6]:
```
df_train.shape # Получим описание pandas DataFrame (количество строк и столбцов)
```

Out[6]:
```
(7500, 17)
```

В [7]:
```
print('Строк в train:', df_train.shape[0])  # gives number of row count
print('Столбцов в train:', df_train.shape[1])  # gives number of col count

print('\nСтрок test:', df_test.shape[0])
print('Столбцов в test:', df_test.shape[1])
```

```
Строк в train: 7500
Столбцов в train: 17

Строк test: 2500
Столбцов в test: 16
```

В [8]:
```
df_train.iloc[0]  # Получаем первую строку (index=0)
```

Out[8]:
```
Home Ownership                      Own Home
Annual Income                         482087
Years in current job                     NaN
Tax Liens                                  0
Number of Open Accounts                   11
Years of Credit History                 26.3
Maximum Open Credit                   685960
Number of Credit Problems                  1
Months since last delinquent             NaN
Bankruptcies                               1
Purpose                   debt consolidation
Term                                Short Term
Current Loan Amount                    1e+08
Current Credit Balance                 47386
Monthly Debt                            7914
Credit Score                             749
Credit Default                             0
Name: 0, dtype: object
```

В [9]:
```
df_train.info()  # Рассмотрим типы признаков
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7500 entries, 0 to 7499
Data columns (total 17 columns):
 #   Column                         Non-Null Count  Dtype
---  ------                         --------------  -----
 0   Home Ownership                 7500 non-null   object
 1   Annual Income                  5943 non-null   float64
 2   Years in current job           7129 non-null   object
 3   Tax Liens                      7500 non-null   float64
 4   Number of Open Accounts        7500 non-null   float64
 5   Years of Credit History        7500 non-null   float64
 6   Maximum Open Credit            7500 non-null   float64
 7   Number of Credit Problems      7500 non-null   float64
 8   Months since last delinquent   3419 non-null   float64
 9   Bankruptcies                   7486 non-null   float64
 10  Purpose                        7500 non-null   object
 11  Term                           7500 non-null   object
 12  Current Loan Amount            7500 non-null   float64
 13  Current Credit Balance         7500 non-null   float64
 14  Monthly Debt                   7500 non-null   float64
 15  Credit Score                   5943 non-null   float64
 16  Credit Default                 7500 non-null   int64
dtypes: float64(12), int64(1), object(4)
memory usage: 996.2+ KB
```

В [10]:
```
#df_train.dtypes
```

1. Обзор данных (Обзор обучающего датасета)

Обзор целевой переменной

В [11]:
```
df_train['Credit Default'].value_counts()  # Количество различных значений признака 'Credit
```

Out[11]:
```
0    5387
1    2113
Name: Credit Default, dtype: int64
```

B [12]:
```
counts = df_train['Credit Default'].value_counts()

plt.figure(figsize=(5,8))
plt.title('Credit Default')
sns.barplot(counts.index, counts.values)

plt.show()
```

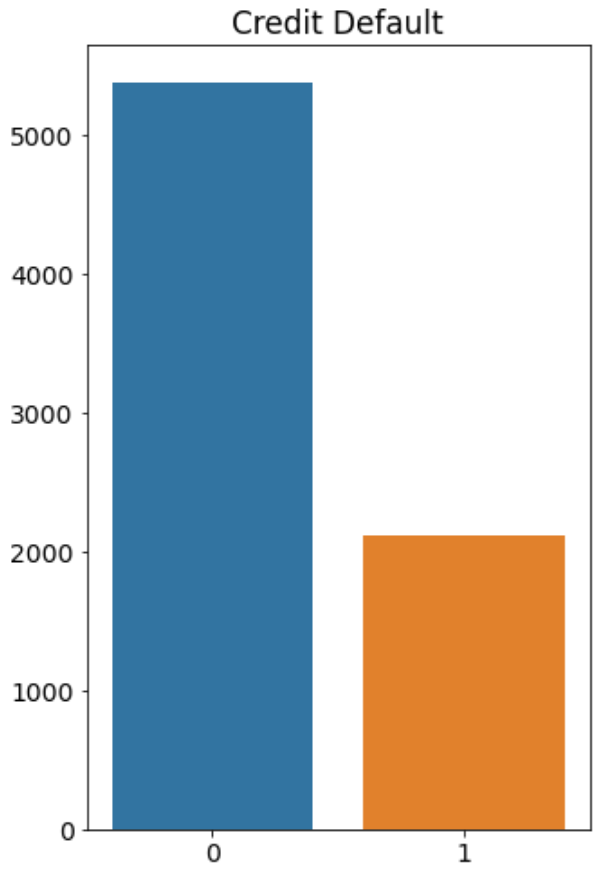

Приведение типов

B [13]:
```
for colname in ['Tax Liens', 'Number of Credit Problems', 'Bankruptcies']:
    df_train[colname] = df_train[colname].astype(str)
```

B [14]:
```
df_train.dtypes
```

Out[14]:
```
Home Ownership                 object
Annual Income                 float64
Years in current job           object
Tax Liens                      object
Number of Open Accounts       float64
Years of Credit History       float64
Maximum Open Credit           float64
Number of Credit Problems      object
Months since last delinquent  float64
Bankruptcies                   object
Purpose                        object
Term                           object
Current Loan Amount           float64
Current Credit Balance        float64
Monthly Debt                  float64
Credit Score                  float64
Credit Default                  int64
dtype: object
```

Обзор количественных признаков

B [15]:
```
df_train.describe().T  # Анализ количественные признаки
```

Out[15]:

	count	mean	std	min	25%	50%	75%	max
Annual Income	5943.0	1.366392e+06	8.453392e+05	164597.0	844341.0	1168386.0	1640137.00	1.014934e+07
Number of Open Accounts	7500.0	1.113093e+01	4.908924e+00	2.0	8.0	10.0	14.00	4.300000e+01
Years of Credit History	7500.0	1.831747e+01	7.041946e+00	4.0	13.5	17.0	21.80	5.770000e+01
Maximum Open Credit	7500.0	9.451537e+05	1.602622e+07	0.0	279229.5	478159.0	793501.50	1.304726e+09
Months since last delinquent	3419.0	3.469260e+01	2.168881e+01	0.0	16.0	32.0	50.00	1.180000e+02
Current Loan Amount	7500.0	1.187318e+07	3.192612e+07	11242.0	180169.0	309573.0	519882.00	1.000000e+08
Current Credit Balance	7500.0	2.898332e+05	3.178714e+05	0.0	114256.5	209323.0	360406.25	6.506797e+06
Monthly Debt	7500.0	1.831445e+04	1.192676e+04	0.0	10067.5	16076.5	23818.00	1.366790e+05
Credit Score	5943.0	1.151087e+03	1.604451e+03	585.0	711.0	731.0	743.00	7.510000e+03
Credit Default	7500.0	2.817333e-01	4.498740e-01	0.0	0.0	0.0	1.00	1.000000e+00

B [16]:
```
df_num_features = df_train.select_dtypes(include=['float32', 'float64', 'int8', 'int16', 'i

df_num_features.hist(figsize=(16, 20), bins=50, grid=True)
```

Out[16]:
```
array([[<AxesSubplot:title={'center':'Annual Income'}>,
        <AxesSubplot:title={'center':'Number of Open Accounts'}>,
        <AxesSubplot:title={'center':'Years of Credit History'}>],
       [<AxesSubplot:title={'center':'Maximum Open Credit'}>,
        <AxesSubplot:title={'center':'Months since last delinquent'}>,
        <AxesSubplot:title={'center':'Current Loan Amount'}>],
       [<AxesSubplot:title={'center':'Current Credit Balance'}>,
        <AxesSubplot:title={'center':'Monthly Debt'}>,
        <AxesSubplot:title={'center':'Credit Score'}>]], dtype=object)
```

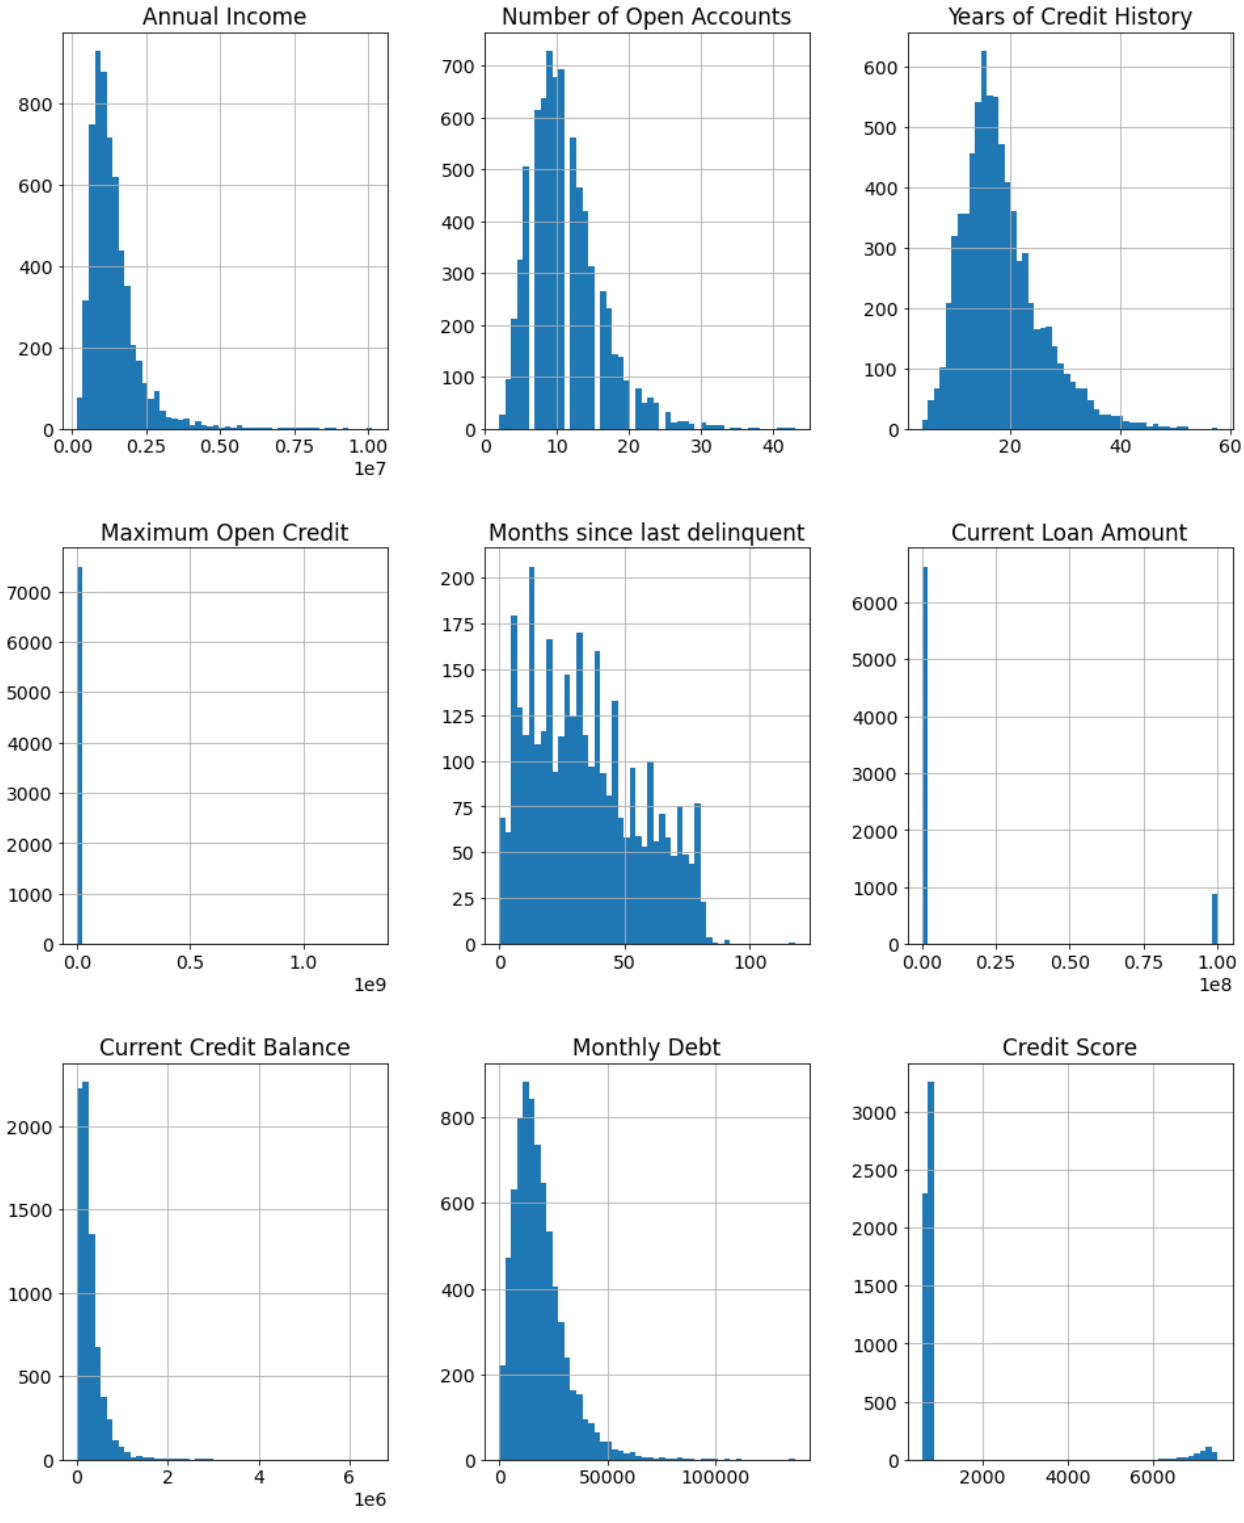

Наблюдаются выбросы по следующим признакам: Current Loan Amount, Maximum Open Credit, Current Credit Balance.

Ряд признаков имеют аномально высокое значение, но вполне вероятное: . Их необходимо будет ограничить.

В [17]:
```
def plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type, c
    '''Производим анализ фичи'''

    print(f'feature_name = {feature_name}' +
          f'\nfeature_value_max = {feature_value_max}' +
          f'\nfeature_value_min = {feature_value_min}')

    # прямая сортировка
    print('_'*50+'\n\nКоличество\n'+'_'*50)
    if count_sort == 0:
        print(df_train[feature_name].value_counts().sort_values())  # по значению
    else:
        print(df_train[feature_name].value_counts().sort_index())  # по индексу

    # обратная сортировка
    # print('_'*50+'\n\nКоличество\n'+'_'*50)
    # nt(df_train[feature_name].value_counts().sort_index(ascending=False).sort_values(asce
    #print(df_train[feature_name].sort_values().value_counts())

    print('_'*50+'\n\nОтсортированные записи\n'+'_'*50)
    print(df_train[feature_name].sort_values())

    if data_type != 2:
        print('_' * 50 + '\n\nПервичный датасет\n' +
            f'\nМода датасета: {df_train[feature_name].mode()[0]}' +
            f'\nМедиана датасета: {df_train[feature_name].median()}' +
            f'\nСреднее значение датасета: {df_train[feature_name].mean()}' +
            f'\nМаксимальное значение датасета: {df_train[feature_name].max()}' +
            f'\nМинимальное значение датасета: {df_train[feature_name].min()}' + '\n' +
            '_' * 50)

    if data_type == 0:
        # 1-й график
        fig, ax = plt.subplots(nrows=1, ncols=1)
        plt.xlabel(feature_name)
        plt.ylabel('Count')
        plt.title('\nПервичный датасет\n')
        #plt.title(r'$\mathrm{Histogram\ of\ IQ:}\ \mu=100,\ \sigma=15$')
        #plt.axis([0, 100000, 0, 900])
        plt.grid(True)
        df_train[feature_name].hist(bins=50)

        print('\nКоличество записей в датасете:', df_train.shape[0])
        df = df_train.loc[(df_train[feature_name] < feature_value_min)]
        print('Количество записей в датасете < {0}: {1}'.format(feature_value_min, df.shape
        df = df_train.loc[(df_train[feature_name] > feature_value_max)]
        print('Количество записей в датасете > {0}: {1}'.format(feature_value_max, df.shape
        print('_' * 50)

        df = df_train.loc[(df_train[feature_name] <= feature_value_max) & (df_train[feature_

        # 2-й график
        fig, ax = plt.subplots(nrows=1, ncols=1)
        plt.xlabel(feature_name)
        plt.ylabel('Count')
        plt.title('\nОбработанный датасет')
        plt.grid(True)
        df[feature_name].hist(bins=50)

        print('\nОбработанный датасет\n' +
            f'\nМода датасета: {df[feature_name].mode()[0]}' +
            f'\nМедиана датасета: {df[feature_name].median()}' +
            f'\nСреднее значение датасета: {df[feature_name].mean()}' +
```

```
            f'\nМаксимальное значение датасета: {df[feature_name].max()}' +
            f'\nМинимальное значение датасета: {df[feature_name].min()}' + '\n' +
            '_' * 50)

        sns.set_theme(style="ticks")
        #sns.set(context='notebook', font_scale=1, color_codes=False)

        # 3-й график
        fig, ax = plt.subplots(nrows=1, ncols=1)
        sns.boxplot(df[feature_name]);

        ax.xaxis.grid(True)
        ax.set(ylabel='')
        sns.despine(trim=True, left=False)

        # 4-й график
        fig, ax = plt.subplots(nrows=1, ncols=1)
        sns.violinplot(df[feature_name], palette='rainbow');

        ax.xaxis.grid(True)
        ax.set(ylabel='')
        sns.despine(trim=True, left=False)
```

Рассмотрим признаки подробнее

1. Home Ownership - домовладение (категориальные данные)

B [18]:
```
feature_name = 'Home Ownership'
feature_value_max = 10
feature_value_min = 0
data_type = 2
# plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)
```

2. Annual Income - годовой доход

В [19]:
```
feature_name = 'Annual Income'
feature_value_max = 4000000
feature_value_min = 164597
data_type = 0
plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)

# Считаем выбросами Annual Income > 4 000 000 (91 значения) и Annual Income < 164597
# Считаем выбросами Annual Income > 5 000 000 (44 значения)
```

```
feature_name = Annual Income
feature_value_max = 4000000
feature_value_min = 164597
_____________________________________________________

Количество
_____________________________________________________
2083825.0    1
785954.0     1
266000.0     1
1177411.0    1
1539152.0    1
            ..
969475.0     4
1043651.0    4
1338113.0    4
1058376.0    4
1161660.0    4
Name: Annual Income, Length: 5478, dtype: int64
_____________________________________________________

Отсортированные записи
_____________________________________________________
4240    164597.0
4485    175845.0
3946    177251.0
3310    191577.0
1114    192223.0
          ...
7482         NaN
7492         NaN
7494         NaN
7498         NaN
7499         NaN
Name: Annual Income, Length: 7500, dtype: float64
_____________________________________________________

Первичный датасет

Мода датасета: 969475.0
Медиана датасета: 1168386.0
Среднее значение датасета: 1366391.7201749957
Максимальное значение датасета: 10149344.0
Минимальное значение датасета: 164597.0
_____________________________________________________

Количество записей в датасете: 7500
Количество записей в датасете < 164597: 0
Количество записей в датасете > 4000000: 91
_____________________________________________________

Обработанный датасет

Мода датасета: 969475.0
```

```
Медиана датасета: 1161432.0
Среднее значение датасета: 1301564.1461038962
Максимальное значение датасета: 3997334.0
Минимальное значение датасета: 164597.0
```

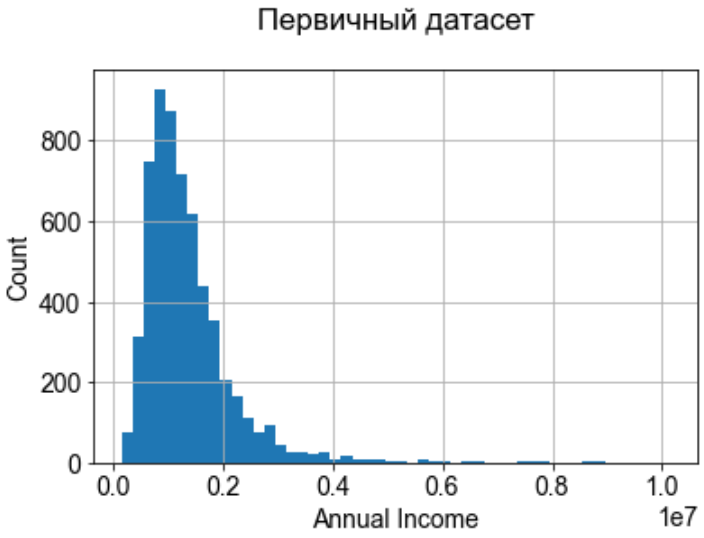

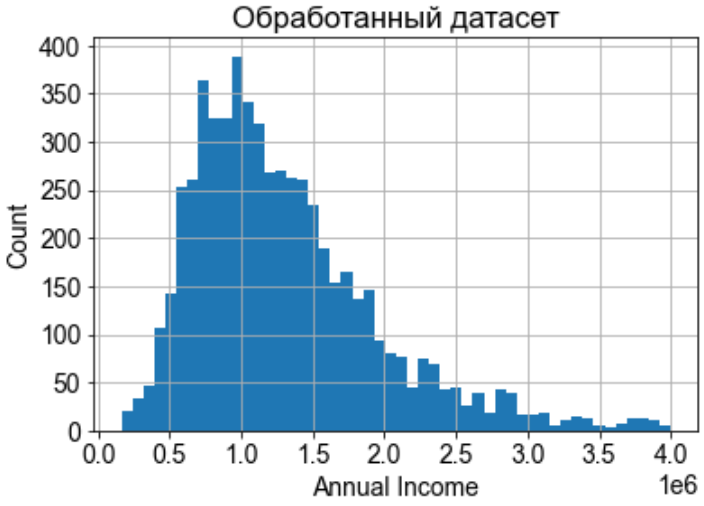

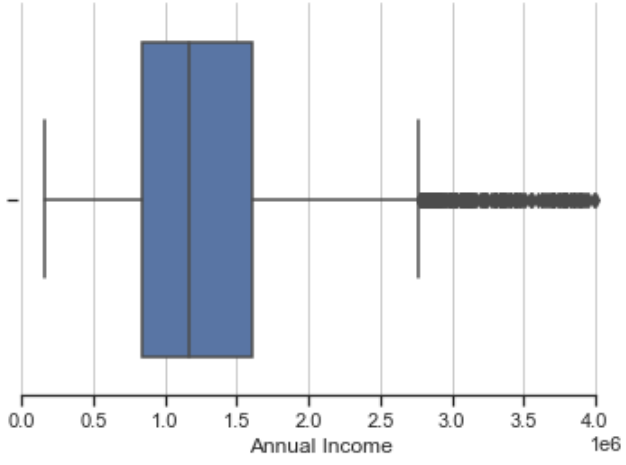

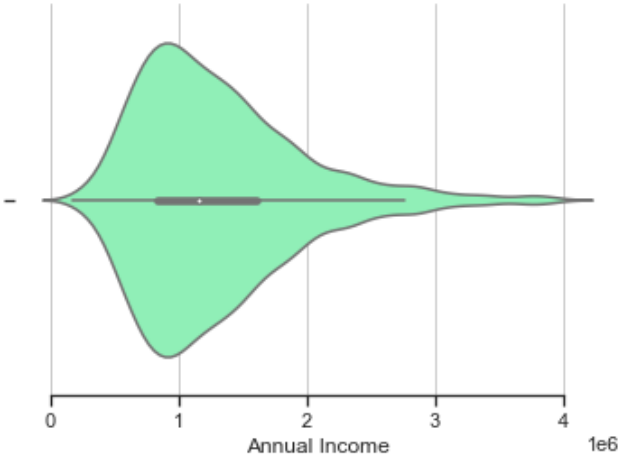

Считаем выбросами **Annual Income** > 5 000 000 (44 значения)

3. Years in current job - количество лет на текущем месте работы (категориальные данные)

B [20]:
```
feature_name = 'Years in current job'
feature_value_max = 5000000
feature_value_min = 0
data_type = 2
# plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)
```

4. Tax Liens - налоговые обременения (категориальные данные)

B [21]:
```
feature_name = 'Tax Liens'
feature_value_max = 4000000
feature_value_min = 0
data_type = 1
# plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)
```

5. Number of Open Accounts - количество открытых счетов

В [22]:
```
feature_name = 'Number of Open Accounts'
feature_value_max = 33
feature_value_min = 0
data_type = 0
plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)

# Считаем выбросами Number of Open Accounts > 33 (9 значений)
```

```
feature_name = Number of Open Accounts
feature_value_max = 33
feature_value_min = 0
_____________________________________________________

Количество
_____________________________________________________
42.0      1
43.0      1
38.0      1
41.0      1
35.0      1
37.0      2
34.0      2
31.0      6
33.0      6
32.0      6
29.0     10
30.0     11
26.0     12
27.0     14
28.0     14
2.0      28
25.0     32
22.0     49
24.0     50
23.0     59
21.0     78
20.0     93
3.0      95
19.0    139
18.0    143
4.0     212
17.0    232
16.0    265
15.0    313
5.0     325
14.0    420
13.0    465
6.0     504
12.0    562
7.0     613
8.0     638
10.0    677
11.0    692
9.0     728
Name: Number of Open Accounts, dtype: int64
_____________________________________________________

Отсортированные записи
_____________________________________________________
3271     2.0
3768     2.0
2321     2.0
2325     2.0
```

```
1743     2.0
        ...
6868    37.0
3475    38.0
2840    41.0
5738    42.0
1769    43.0
Name: Number of Open Accounts, Length: 7500, dtype: float64
```

Первичный датасет

Мода датасета: 9.0
Медиана датасета: 10.0
Среднее значение датасета: 11.130933333333333
Максимальное значение датасета: 43.0
Минимальное значение датасета: 2.0

Количество записей в датасете: 7500
Количество записей в датасете < 0: 0
Количество записей в датасете > 33: 9

Обработанный датасет

Мода датасета: 9.0
Медиана датасета: 10.0
Среднее значение датасета: 11.098785208917368
Максимальное значение датасета: 33.0
Минимальное значение датасета: 2.0

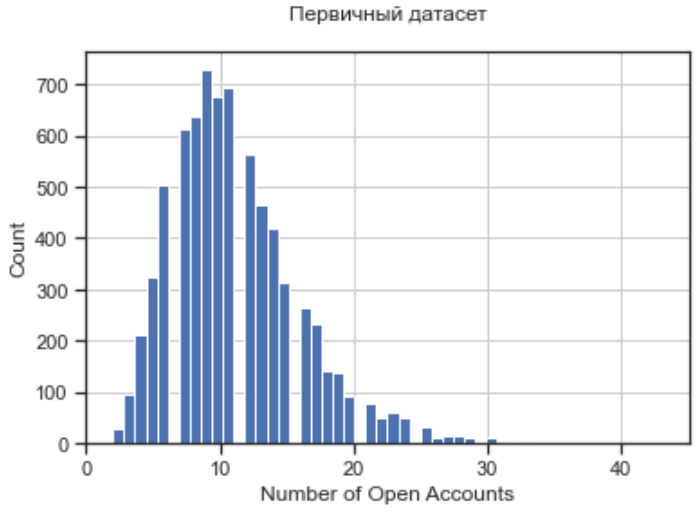

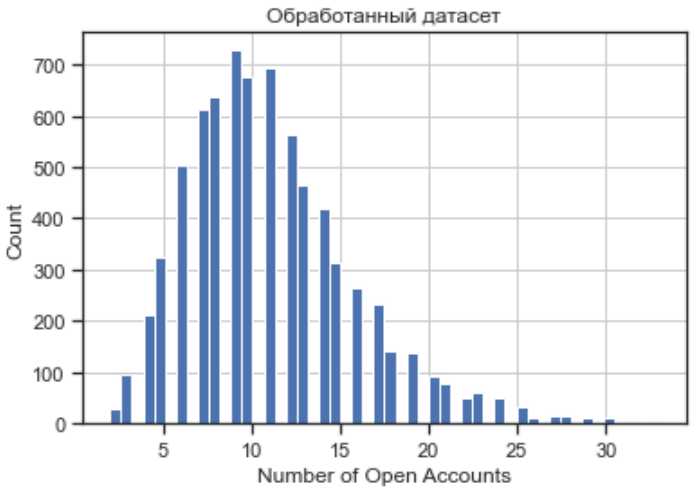

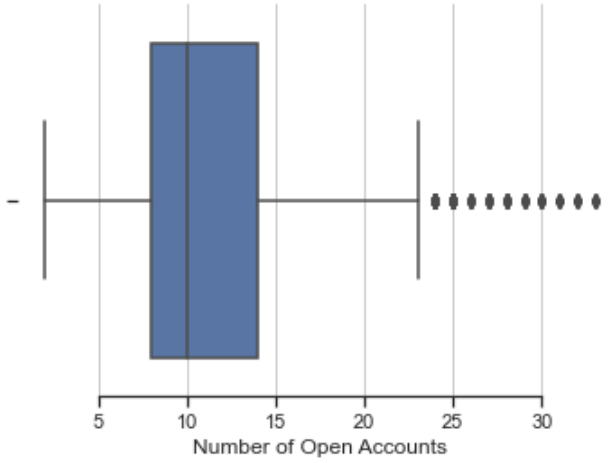

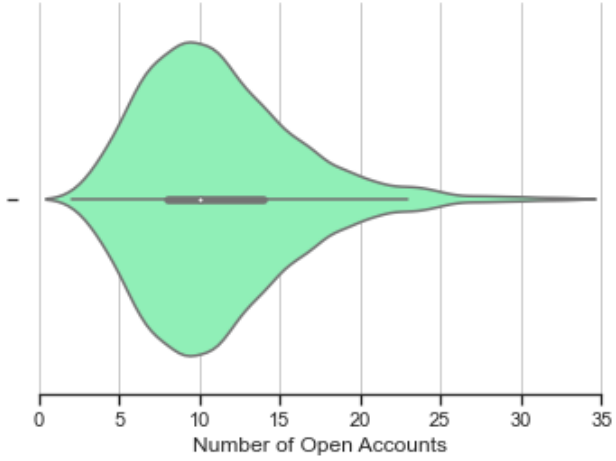

6. Years of Credit History - количество лет кредитной истории

В [23]:
```
feature_name = 'Years of Credit History'
feature_value_max = 40
feature_value_min = 0
data_type = 0
plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)

# Считаем выбросами Years of Credit History > 40 (83 значения)
# Считаем выбросами Years of Credit History > 50 (8 значения)
```

```
feature_name = Years of Credit History
feature_value_max = 40
feature_value_min = 0
_____________________________________________________

Количество
_____________________________________________________
39.8      1
41.8      1
46.3      1
6.2       1
36.3      1
        ...
17.5     83
17.0     86
16.5     91
16.0     99
15.0    104
Name: Years of Credit History, Length: 408, dtype: int64
_____________________________________________________

Отсортированные записи
_____________________________________________________
324      4.0
5497     4.3
3784     4.5
2560     4.5
6633     4.7
         ...
3628    51.3
4716    51.5
4301    51.9
247     52.2
476     57.7
Name: Years of Credit History, Length: 7500, dtype: float64
_____________________________________________________

Первичный датасет

Мода датасета: 15.0
Медиана датасета: 17.0
Среднее значение датасета: 18.317466666666647
Максимальное значение датасета: 57.7
Минимальное значение датасета: 4.0
_____________________________________________________

Количество записей в датасете: 7500
Количество записей в датасете < 0: 0
Количество записей в датасете > 40: 83
_____________________________________________________

Обработанный датасет

Мода датасета: 15.0
```

```
Медиана датасета: 17.0
Среднее значение датасета: 18.027747067547494
Максимальное значение датасета: 40.0
Минимальное значение датасета: 4.0
```

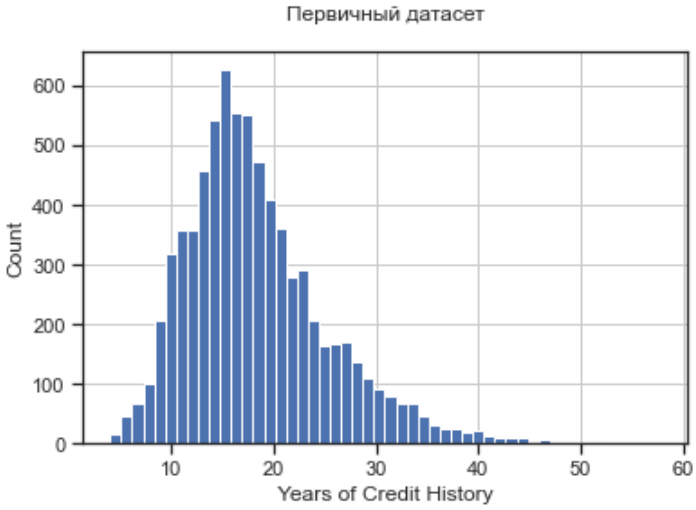

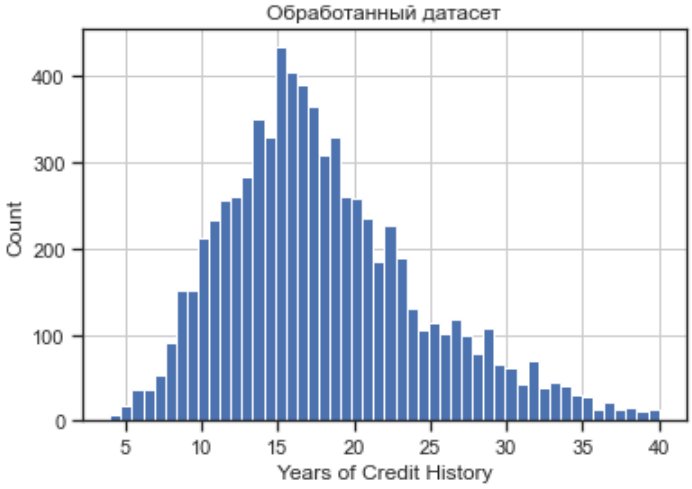

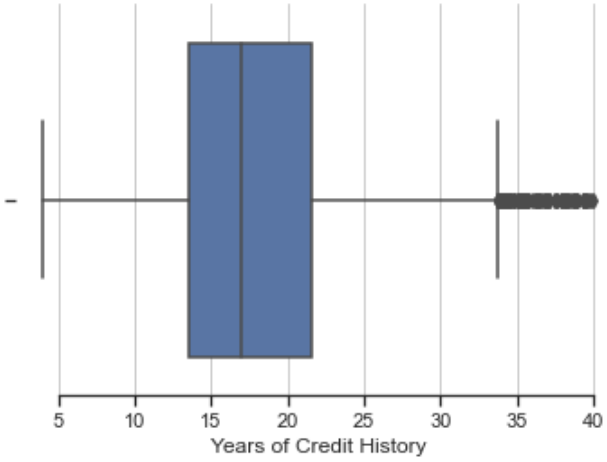

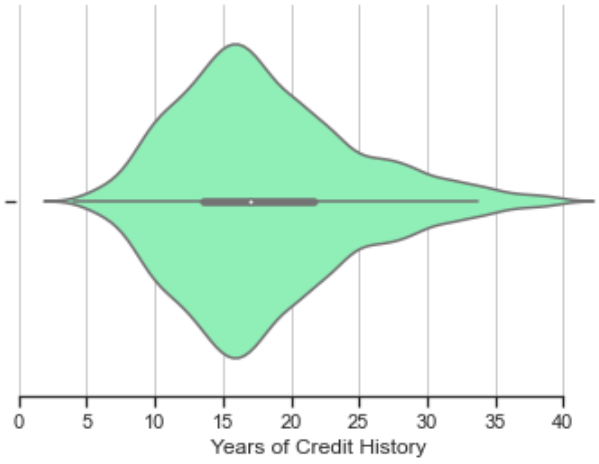

7. Maximum Open Credit - наибольший открытый кредит

В [24]:
```
feature_name = 'Maximum Open Credit'
feature_value_max = 2000000
feature_value_min = 0 # 50000
data_type = 0
plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type, 0)

# Считаем выбросами значения 'Maximum Open Credit' > 4 000 000 (64 значений) 'Maximum Open
# Считаем выбросами значения 'Maximum Open Credit' > 2 000 000 (249 значений) 'Maximum Open
```

```
feature_name = Maximum Open Credit
feature_value_max = 2000000
feature_value_min = 0
_____________________________________________________

Количество
_____________________________________________________
804958.0      1
653488.0      1
368192.0      1
3007136.0     1
243166.0      1
             ..
323312.0      3
615714.0      3
349140.0      3
319110.0      5
0.0          65
Name: Maximum Open Credit, Length: 6963, dtype: int64
_____________________________________________________

Отсортированные записи
_____________________________________________________
2297    0.000000e+00
319     0.000000e+00
611     0.000000e+00
1427    0.000000e+00
294     0.000000e+00
           ...
2763    4.092389e+07
2023    5.756256e+07
2617    2.655129e+08
44      3.800523e+08
617     1.304726e+09
Name: Maximum Open Credit, Length: 7500, dtype: float64
_____________________________________________________

Первичный датасет

Мода датасета: 0.0
Медиана датасета: 478159.0
Среднее значение датасета: 945153.7274666667
Максимальное значение датасета: 1304726170.0
Минимальное значение датасета: 0.0
_____________________________________________________

Количество записей в датасете: 7500
Количество записей в датасете < 0: 0
Количество записей в датасете > 2000000: 249
_____________________________________________________

Обработанный датасет

Мода датасета: 0.0
```

```
Медиана датасета: 463452.0
Среднее значение датасета: 559819.0845400634
Максимальное значение датасета: 1992298.0
Минимальное значение датасета: 0.0
```

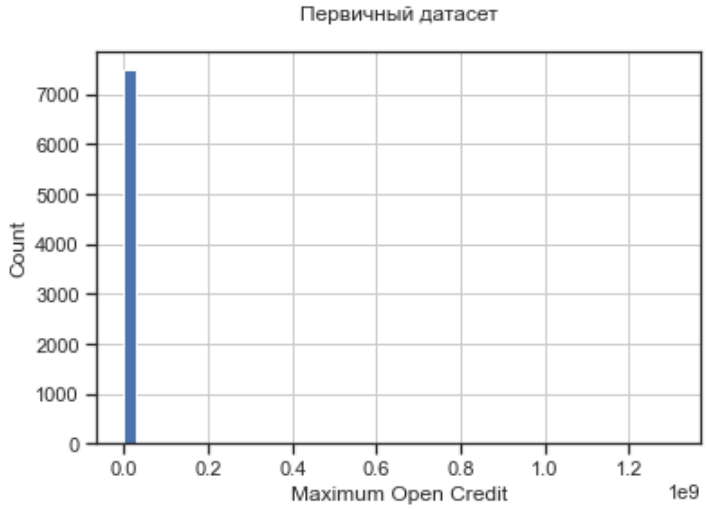

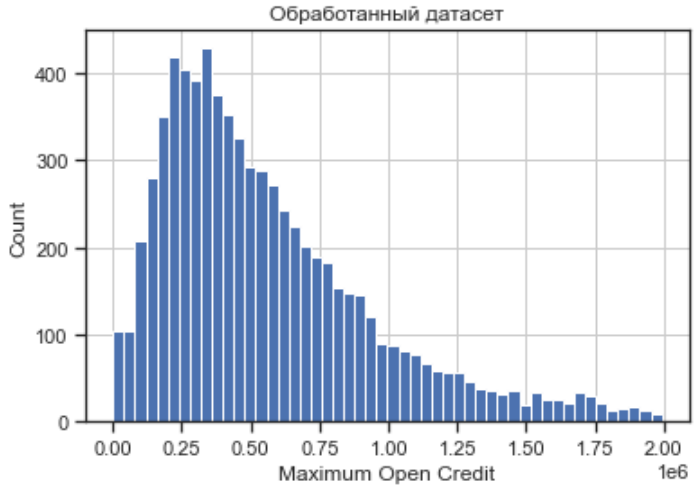

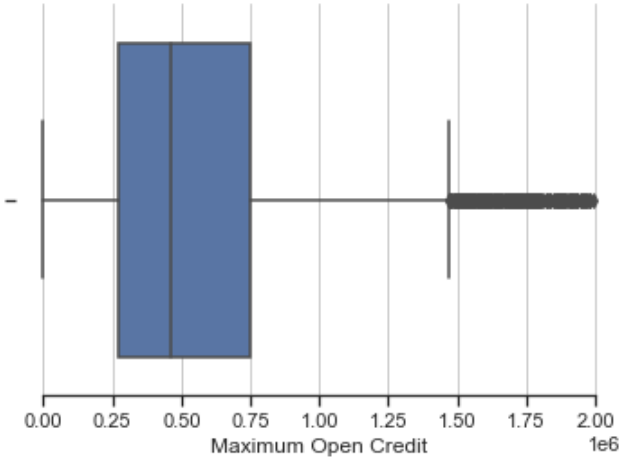

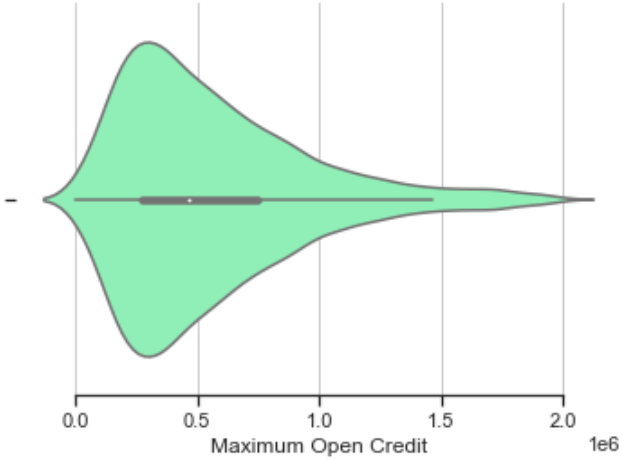

Считаем выбросами значения 'Maximum Open Credit' > 2 000 000 (249 значений) 'Maximum Open Credit' < 50 000 (125 значений)

8. Number of Credit Problems - количество проблем с кредитом (категориальные данные)

B [25]:
```
feature_name = 'Number of Credit Problems'
feature_value_max = 7
feature_value_min = 0
data_type = 1
# plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)
```

9. Months since last delinquent - количество месяцев с последней просрочки платежа

B [26]:
```
feature_name = 'Months since last delinquent'
feature_value_max = 83
feature_value_min = 0
data_type = 0
print(np.sort(df_train['Months since last delinquent'].unique()))

plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)

# Считаем выбросами Months since last delinquent > 83 (5 значений)
```

```
[  0.   1.   2.   3.   4.   5.   6.   7.   8.   9.  10.  11.  12.  13.
  14.  15.  16.  17.  18.  19.  20.  21.  22.  23.  24.  25.  26.  27.
  28.  29.  30.  31.  32.  33.  34.  35.  36.  37.  38.  39.  40.  41.
  42.  43.  44.  45.  46.  47.  48.  49.  50.  51.  52.  53.  54.  55.
  56.  57.  58.  59.  60.  61.  62.  63.  64.  65.  66.  67.  68.  69.
  70.  71.  72.  73.  74.  75.  76.  77.  78.  79.  80.  81.  82.  83.
  84.  86.  91.  92. 118.  nan]
feature_name = Months since last delinquent
feature_value_max = 83
feature_value_min = 0
_____________________________________________________

Количество
_____________________________________________________
91.0      1
86.0      1
84.0      1
118.0     1
92.0      1
         ..
13.0     65
33.0     68
8.0      68
29.0     71
14.0     76
Name: Months since last delinquent, Length: 89, dtype: int64
_____________________________________________________

Отсортированные записи
_____________________________________________________
5705    0.0
4995    0.0
4938    0.0
3063    0.0
257     0.0
       ...
7494    NaN
7495    NaN
7497    NaN
7498    NaN
7499    NaN
Name: Months since last delinquent, Length: 7500, dtype: float64
_____________________________________________________

Первичный датасет

Мода датасета: 14.0
Медиана датасета: 32.0
Среднее значение датасета: 34.69260017548991
Максимальное значение датасета: 118.0
Минимальное значение датасета: 0.0

_____________________________________________________
```

```
Количество записей в датасете: 7500
Количество записей в датасете < 0: 0
Количество записей в датасете > 83: 5
```

```
Обработанный датасет

Мода датасета: 14.0
Медиана датасета: 32.0
Среднее значение датасета: 34.605448154657296
Максимальное значение датасета: 83.0
Минимальное значение датасета: 0.0
```

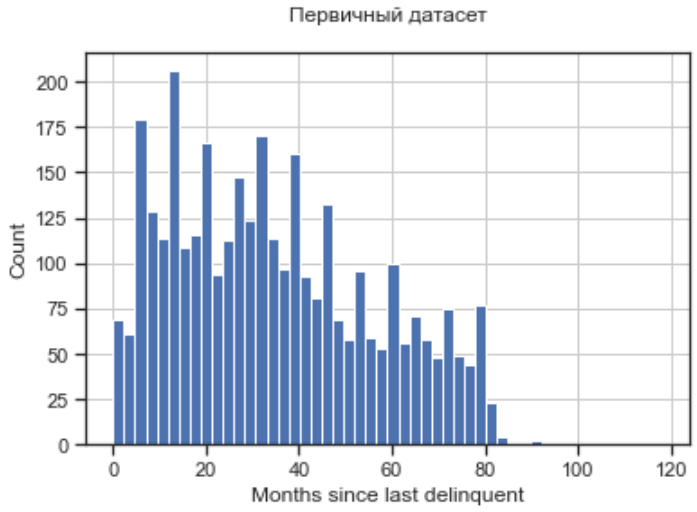

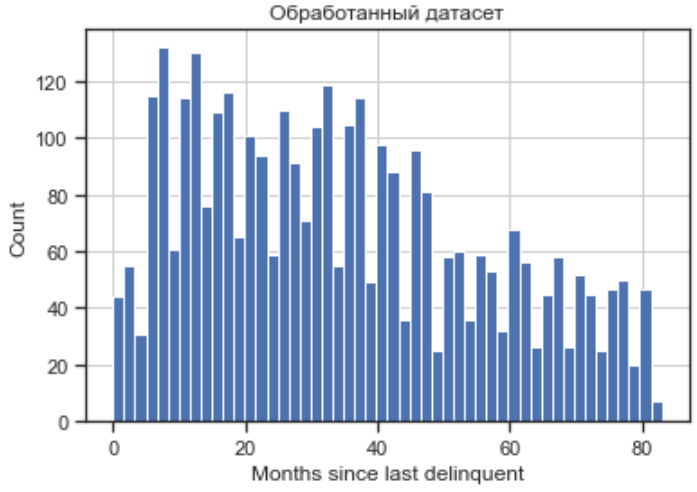

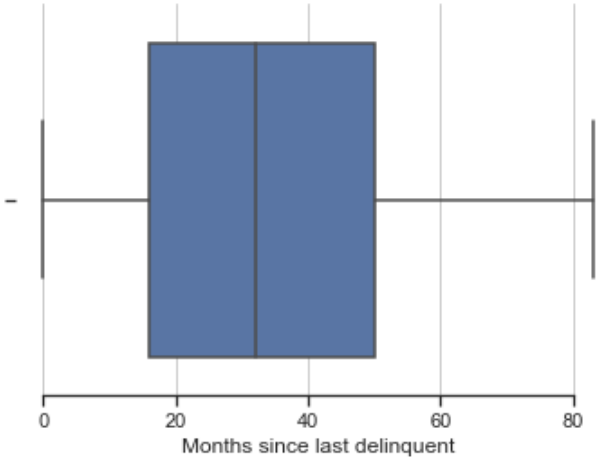

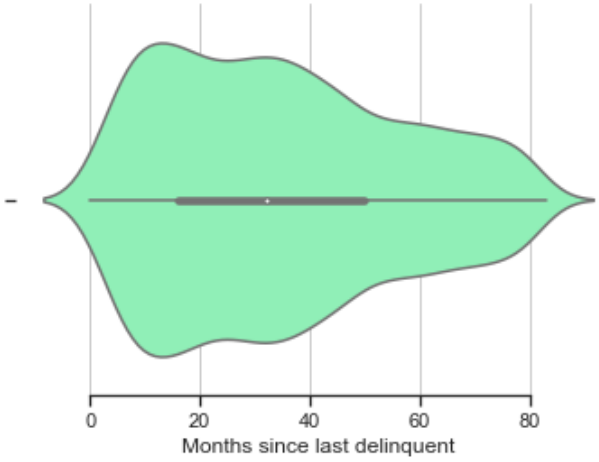

Считаем выбросами **Months since last delinquent** > 83

10. Bankruptcies - банкротства (категориальные данные)

B [27]:
```
feature_name = 'Bankruptcies'
feature_value_max = 4
feature_value_min = 0
data_type = 1
# plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)
```

11. Purpose - цель кредита (категориальные данные)

B [28]:
```
feature_name = 'Purpose'
feature_value_max = 136679
feature_value_min = 0
data_type = 2
# plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)
```

12. Term - срок кредита (категориальные данные)

B [29]:
```
feature_name = 'Term'
feature_value_max = 136679
feature_value_min = 0
data_type = 2
# plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)
```

13. Current Loan Amount - текущая сумма кредита

В [30]:
```
feature_name = 'Current Loan Amount'
feature_value_max = 99999999
feature_value_min = 0
data_type = 0
plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type, 1)

# выбросы 99999999.0 (870 записей)

# Набор данных надо разбивать на два по сумме кредита: 1 - [0, ...,2*10^7], 2 - [85*10^7, .
```

```
feature_name = Current Loan Amount
feature_value_max = 99999999
feature_value_min = 0
_____________________________________________________

Количество
_____________________________________________________
11242.0         1
21472.0         2
21516.0         1
21560.0         1
21582.0         1
               ...
788634.0        2
788788.0        1
788942.0        1
789030.0        1
99999999.0    870
Name: Current Loan Amount, Length: 5386, dtype: int64
_____________________________________________________

Отсортированные записи
_____________________________________________________
1404       11242.0
4467       21472.0
2735       21472.0
7144       21516.0
5861       21560.0
           ...
4384    99999999.0
732     99999999.0
4374    99999999.0
4555    99999999.0
0       99999999.0
Name: Current Loan Amount, Length: 7500, dtype: float64
_____________________________________________________

Первичный датасет

Мода датасета: 99999999.0
Медиана датасета: 309573.0
Среднее значение датасета: 11873177.445066666
Максимальное значение датасета: 99999999.0
Минимальное значение датасета: 11242.0
_____________________________________________________

Количество записей в датасете: 7500
Количество записей в датасете < 0: 0
Количество записей в датасете > 99999999: 0
_____________________________________________________

Обработанный датасет
```

```
Мода датасета: 99999999.0
Медиана датасета: 309573.0
Среднее значение датасета: 11873177.445066666
Максимальное значение датасета: 99999999.0
Минимальное значение датасета: 11242.0
```

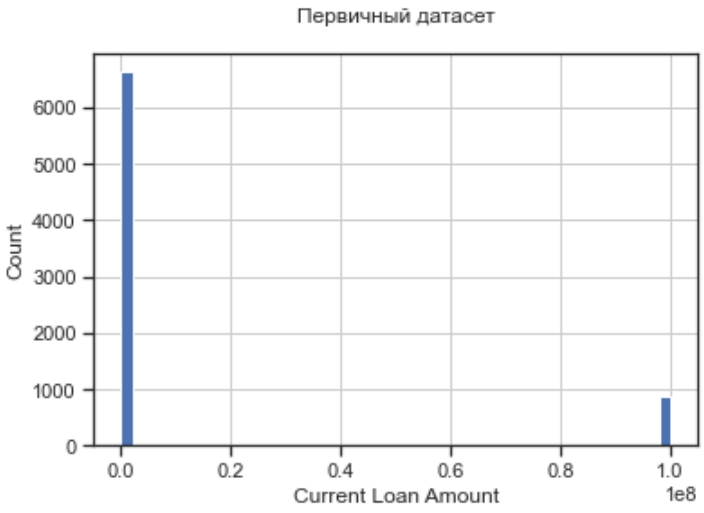

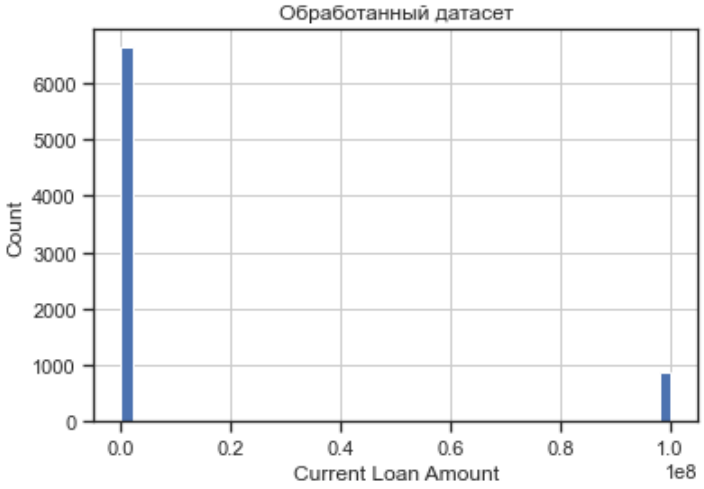

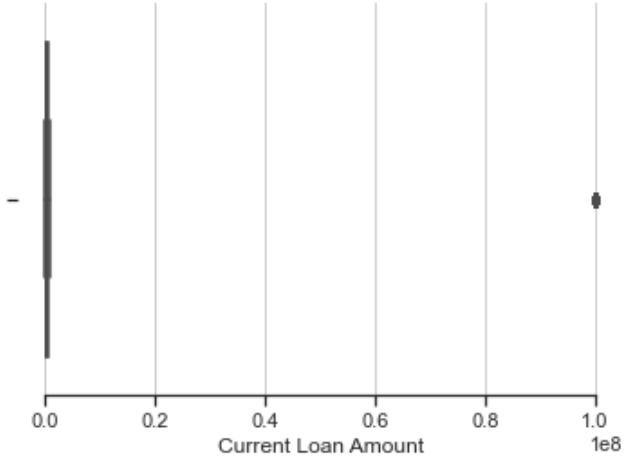

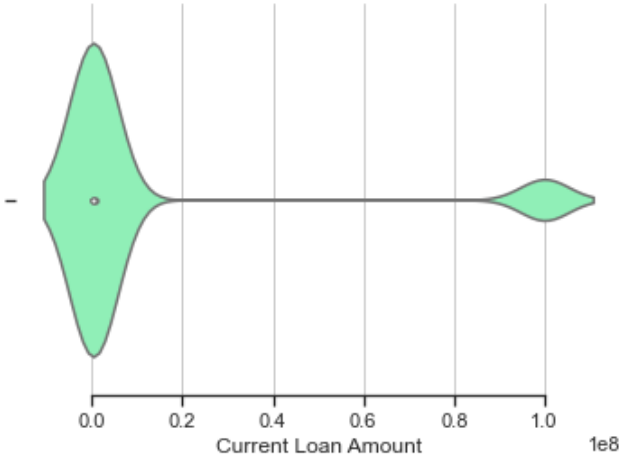

14. Current Credit Balance - текущий кредитный баланс

В [31]:
```
feature_name = 'Current Credit Balance'
feature_value_max = 1300000
feature_value_min = 0
data_type = 0

plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)

# Считаем выбросами значения 'Current Credit Balance' > 1300000 (106 значений)
# Считаем выбросами значения 'Current Credit Balance' > 2500000 (21 значений)
```

```
feature_name = Current Credit Balance
feature_value_max = 1300000
feature_value_min = 0
_____________________________________________________

Количество
_____________________________________________________
250477.0     1
474601.0     1
134900.0     1
150366.0     1
153026.0     1
            ..
198911.0     4
136401.0     4
82289.0      4
191710.0     5
0.0         53
Name: Current Credit Balance, Length: 6592, dtype: int64
_____________________________________________________

Отсортированные записи
_____________________________________________________
4405          0.0
4274          0.0
1802          0.0
1464          0.0
2276          0.0
           ...
7278    4209659.0
1580    4249673.0
4602    4367245.0
4745    4720132.0
4769    6506797.0
Name: Current Credit Balance, Length: 7500, dtype: float64
_____________________________________________________

Первичный датасет

Мода датасета: 0.0
Медиана датасета: 209323.0
Среднее значение датасета: 289833.2352
Максимальное значение датасета: 6506797.0
Минимальное значение датасета: 0.0
_____________________________________________________

Количество записей в датасете: 7500
Количество записей в датасете < 0: 0
Количество записей в датасете > 1300000: 106
_____________________________________________________

Обработанный датасет
```

```
Мода датасета: 0.0
Медиана датасета: 206188.0
Среднее значение датасета: 264468.74749797134
Максимальное значение датасета: 1288504.0
Минимальное значение датасета: 0.0
```

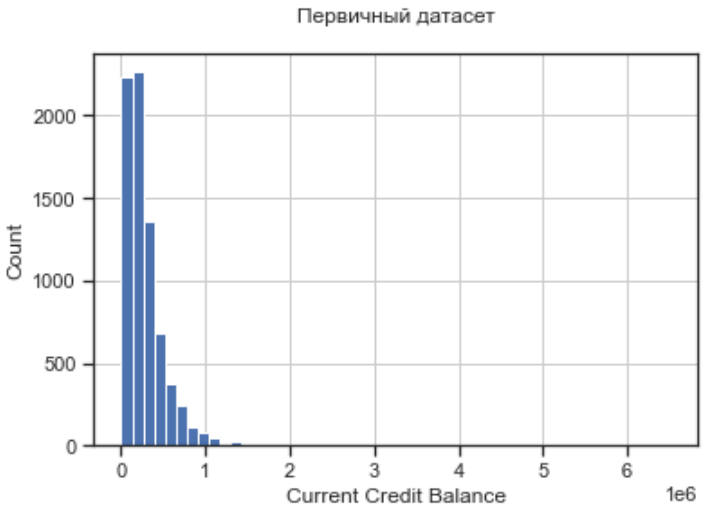

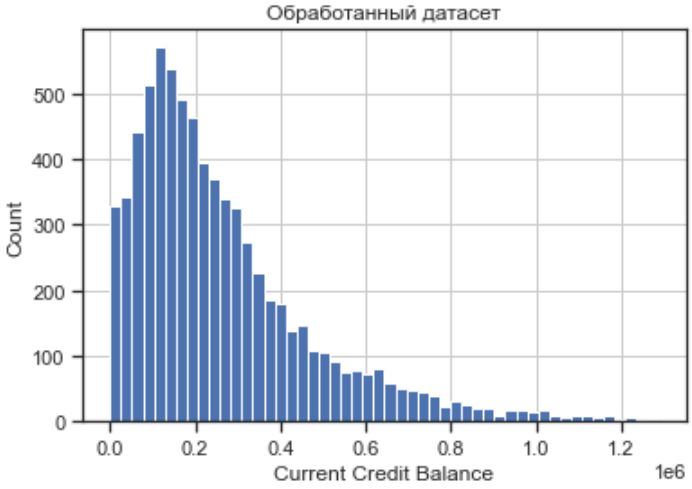

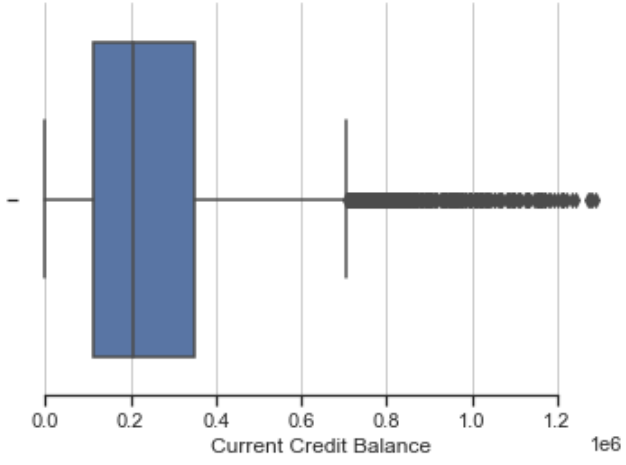

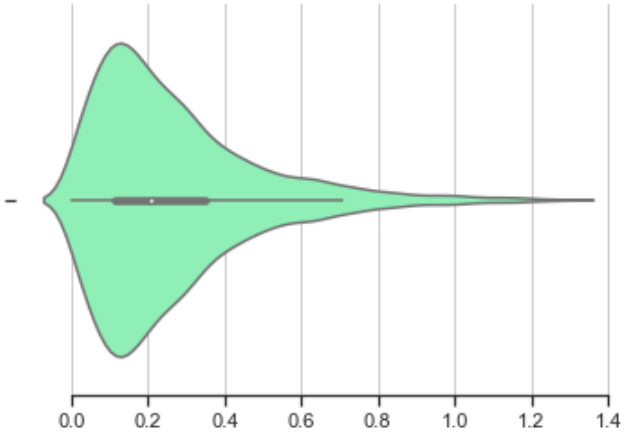

15. Monthly Debt - ежемесячный долг

B [32]:
```
feature_name = 'Monthly Debt'
# feature_value_max = 136679
feature_value_max = 55000
feature_value_min = 0  # 236
data_type = 0

plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)

# Считаем выбросами значения 'Monthly Debt' > 55 000 (98 значений)
# Считаем выбросами значения 'Monthly Debt' > 80 000 (17 значений)
```

```
feature_name = Monthly Debt
feature_value_max = 55000
feature_value_min = 0
_____________________________________________________

Количество
_____________________________________________________
22292.0    1
23287.0    1
14015.0    1
21381.0    1
8390.0     1
          ..
14848.0    3
11659.0    3
19667.0    4
19222.0    4
0.0        6
Name: Monthly Debt, Length: 6716, dtype: int64
_____________________________________________________

Отсортированные записи
_____________________________________________________
780          0.0
1643         0.0
7124         0.0
4165         0.0
3219         0.0
           ...
6253     96177.0
6946    100091.0
2535    104036.0
1615    110311.0
4745    136679.0
Name: Monthly Debt, Length: 7500, dtype: float64
_____________________________________________________

Первичный датасет

Мода датасета: 0.0
Медиана датасета: 16076.5
Среднее значение датасета: 18314.454133333333
Максимальное значение датасета: 136679.0
Минимальное значение датасета: 0.0
_____________________________________________________

Количество записей в датасете: 7500
Количество записей в датасете < 0: 0
Количество записей в датасете > 55000: 98
_____________________________________________________

Обработанный датасет
```

```
Мода датасета: 0.0
Медиана датасета: 15901.0
Среднее значение датасета: 17654.054579843287
Максимальное значение датасета: 54882.0
Минимальное значение датасета: 0.0
```

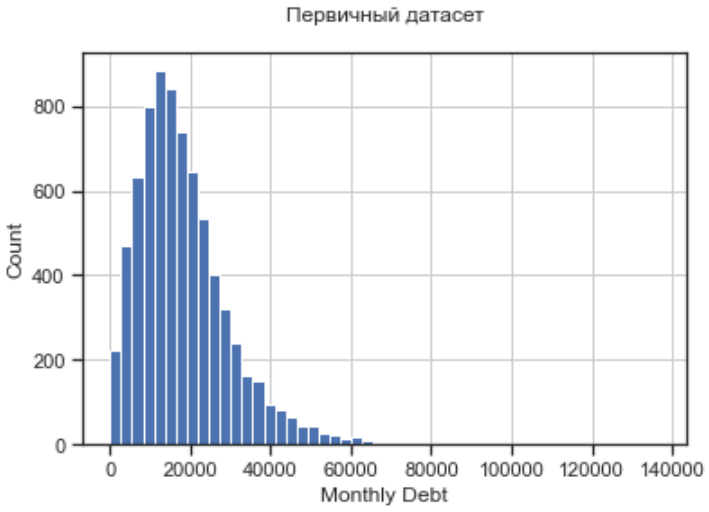

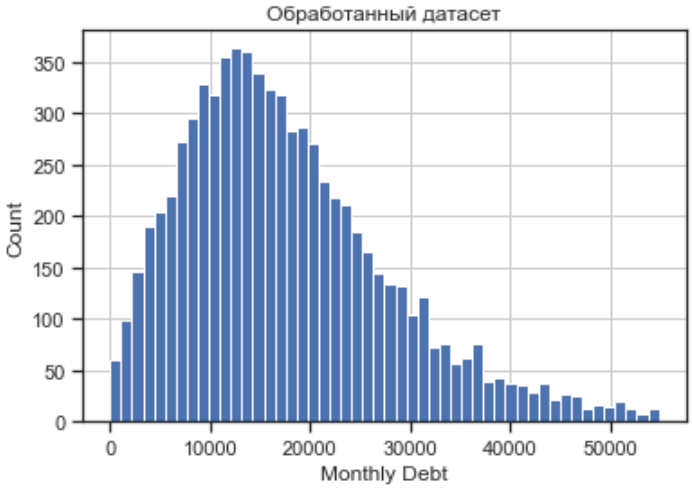

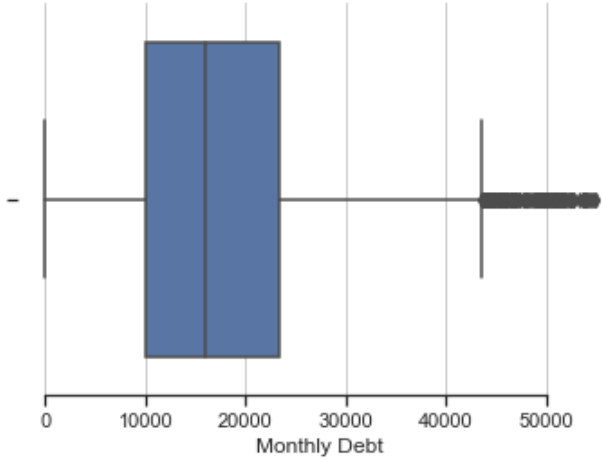

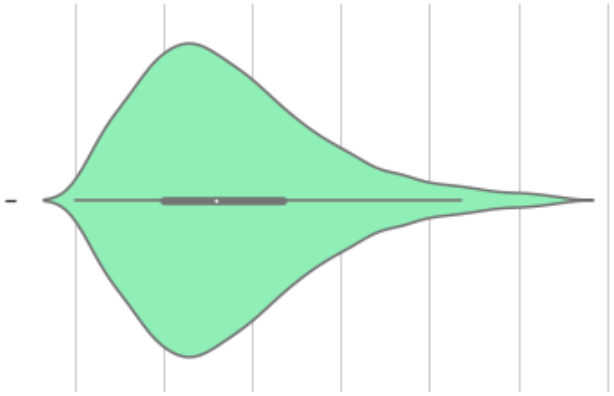

Считаем выбросами значения 'Monthly Debt' > 80 000 (17 значений)

16. Credit Score - Кредитный рейтинг?

В [33]:
```
feature_name = 'Credit Score'
feature_value_max = 1000
feature_value_min = 585
data_type = 0
plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)

# Набор данных надо разбивать на два по Кредитному рейтингу: 1 - [585, ...,800], 2 - [6500,
# Считаем выбросами значения 'Monthly Debt' < 585
```

```
feature_name = Credit Score
feature_value_max = 1000
feature_value_min = 585
```

Количество

```
7010.0      1
6150.0      1
604.0       1
629.0       1
6600.0      1
          ...
741.0     151
745.0     152
748.0     157
747.0     168
740.0     169
Name: Credit Score, Length: 268, dtype: int64
```

Отсортированные записи

```
599     585.0
6114    586.0
1455    588.0
3475    589.0
3491    590.0
        ...
7482      NaN
7492      NaN
7494      NaN
7498      NaN
7499      NaN
Name: Credit Score, Length: 7500, dtype: float64
```

Первичный датасет

```
Мода датасета: 740.0
Медиана датасета: 731.0
Среднее значение датасета: 1151.0874978966851
Максимальное значение датасета: 7510.0
Минимальное значение датасета: 585.0
```

```
Количество записей в датасете: 7500
Количество записей в датасете < 585: 0
Количество записей в датасете > 1000: 400
```

Обработанный датасет

```
Мода датасета: 740.0
```

```
Медиана датасета: 729.0
Среднее значение датасета: 720.7059354140357
Максимальное значение датасета: 751.0
Минимальное значение датасета: 585.0
```

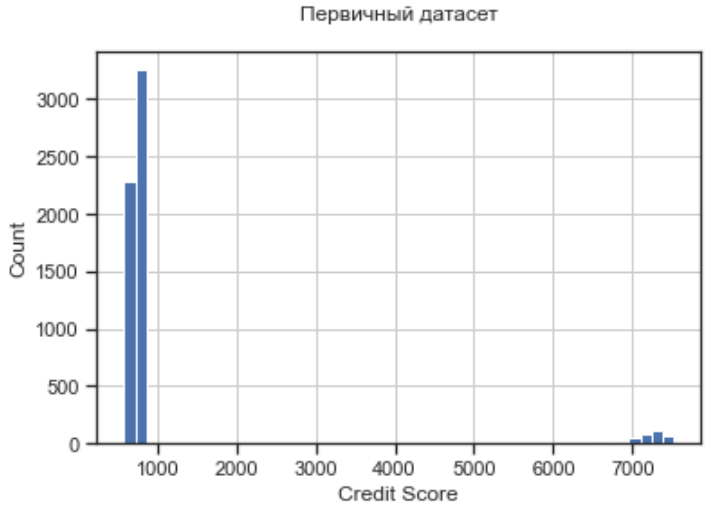

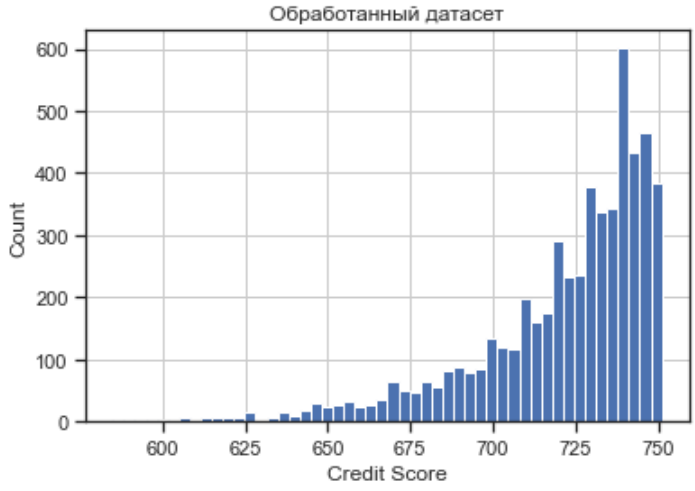

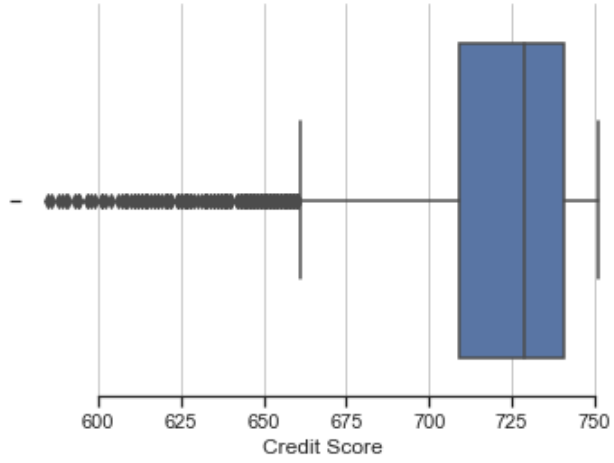

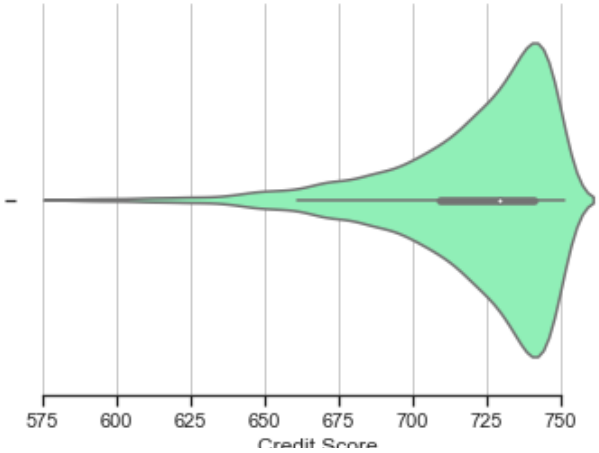

1. **Home Ownership** - домовладение (категориальные данные)

2. **Annual Income** - годовой доход

- **Считаем выбросами Annual Income > 4 000 000 (91 значения)**
- Считаем выбросами Annual Income > 5 000 000 (44 значения)

3. **Years in current job** - количество лет на текущем месте работы (категориальные данные)
4. **Tax Liens** - налоговые обременения (категориальные данные)
5. **Number of Open Accounts** - количество открытых счетов

6. **Years of Credit History** - количество лет кредитной истории

- **Считаем выбросами Years of Credit History > 40 (83 значения)**
- Считаем выбросами Years of Credit History > 50 (8 значения)

7. **Maximum Open Credit** - наибольший открытый кредит

- **Считаем выбросами значения 'Maximum Open Credit' > 4 000 000 (64 значений) 'Maximum Open Credit' < 50 000 (125 значений)**
- Считаем выбросами значения 'Maximum Open Credit' > 2 000 000 (249 значений) 'Maximum Open Credit' < 50 000 (125 значений)

8. **Number of Credit Problems** - количество проблем с кредитом (категориальные данные)

9. **Months since last delinquent** - количество месяцев с последней просрочки платежа

- **Считаем выбросами Months since last delinquent > 83 (5 значений)**

10. **Bankruptcies** - банкротства (категориальные данные)
11. **Purpose** - цель кредита (категориальные данные)
12. **Term** - срок кредита (категориальные данные)

13. **Current Loan Amount** - текущая сумма кредита

- Набор данных надо разбивать на два по сумме кредита: 1 - [0, ..., 2 * 10^7], 2 - [85 * 10^7, ..., 1 * 10^8]
- Проверить коореляцию с Credit Score - Кредитный рейтинг

14. **Current Credit Balance** - текущий кредитный баланс

- **Считаем выбросами значения 'Current Credit Balance' > 1300000 (106 значений)**
- Считаем выбросами значения 'Current Credit Balance' > 2500000 (21 значений)

15. **Monthly Debt** - ежемесячный долг

- **Считаем выбросами значения 'Monthly Debt' > 55 000 (98 значений)**

- Считаем выбросами значения 'Monthly Debt' > 80 000 (17 значений)

16. **Credit Score** - Кредитный рейтинг?

- **Считаем выбросами значения 'Monthly Debt' < 585 и 'Monthly Debt' > 7510**
- Набор данных надо разбивать на два по Кредитному рейтингу: 1 - [585, ...,800], 2 - [6500, ..., 7500]
- Проверить коореляцию с Current Loan Amount - текущая сумма кредита

Анализ признакового пространства¶

Корреляция с базовыми признаками

B [34]:
```
TARGET_NAME = 'Credit Default'
BASE_FEATURE_NAMES = df_train.columns.drop(TARGET_NAME).tolist()
BASE_FEATURE_NAMES
```

Out[34]:
```
['Home Ownership',
 'Annual Income',
 'Years in current job',
 'Tax Liens',
 'Number of Open Accounts',
 'Years of Credit History',
 'Maximum Open Credit',
 'Number of Credit Problems',
 'Months since last delinquent',
 'Bankruptcies',
 'Purpose',
 'Term',
 'Current Loan Amount',
 'Current Credit Balance',
 'Monthly Debt',
 'Credit Score']
```

B [35]:
```
corr_with_target = df_train[BASE_FEATURE_NAMES + [TARGET_NAME]].corr().iloc[:-1, -1].sort_v

plt.figure(figsize=(10, 8))

sns.barplot(x=corr_with_target.values, y=corr_with_target.index)

plt.title('Correlation with target variable')
plt.show()
```

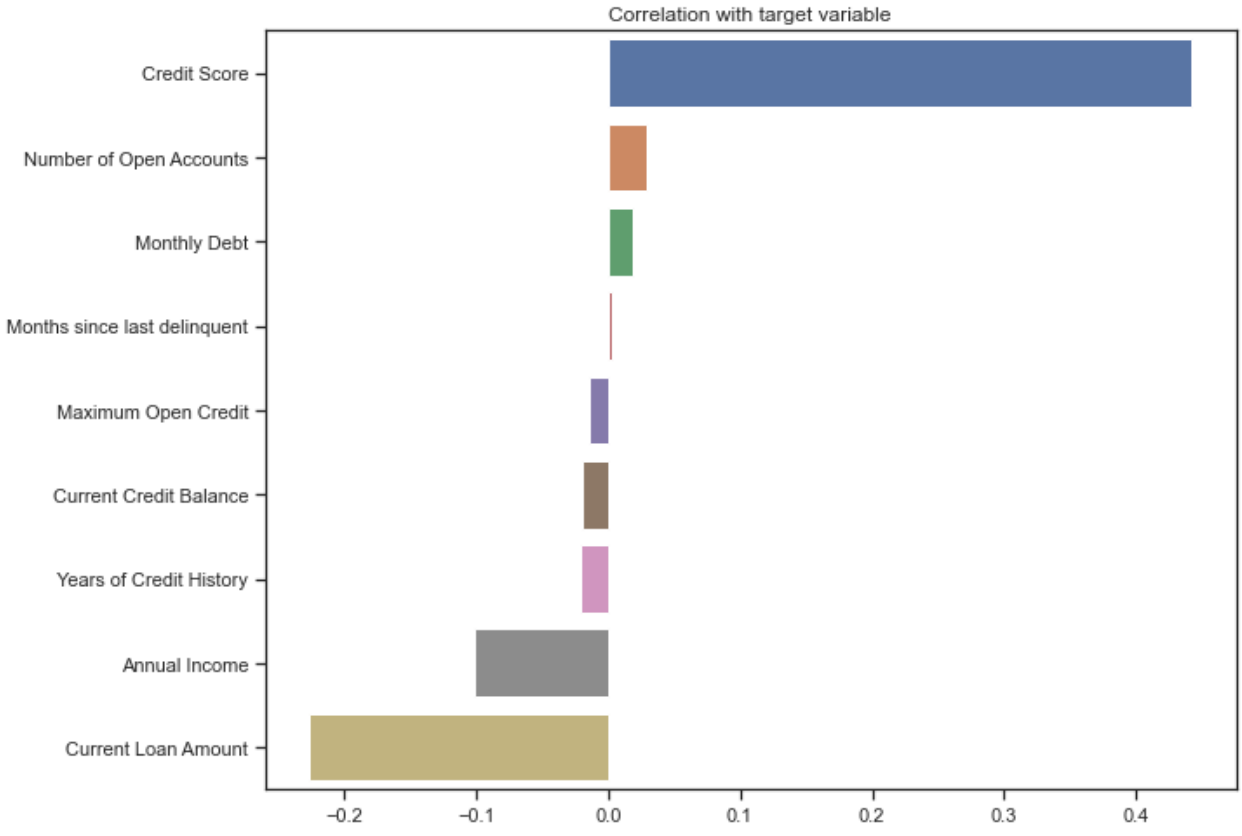

Матрица корреляций

B [36]:
```
plt.figure(figsize = (25,20))

sns.set(font_scale=1.4)
sns.heatmap(df_train[BASE_FEATURE_NAMES].corr().round(3), annot=True, linewidths=.5, cmap='

plt.title('Correlation matrix')
plt.show()
```

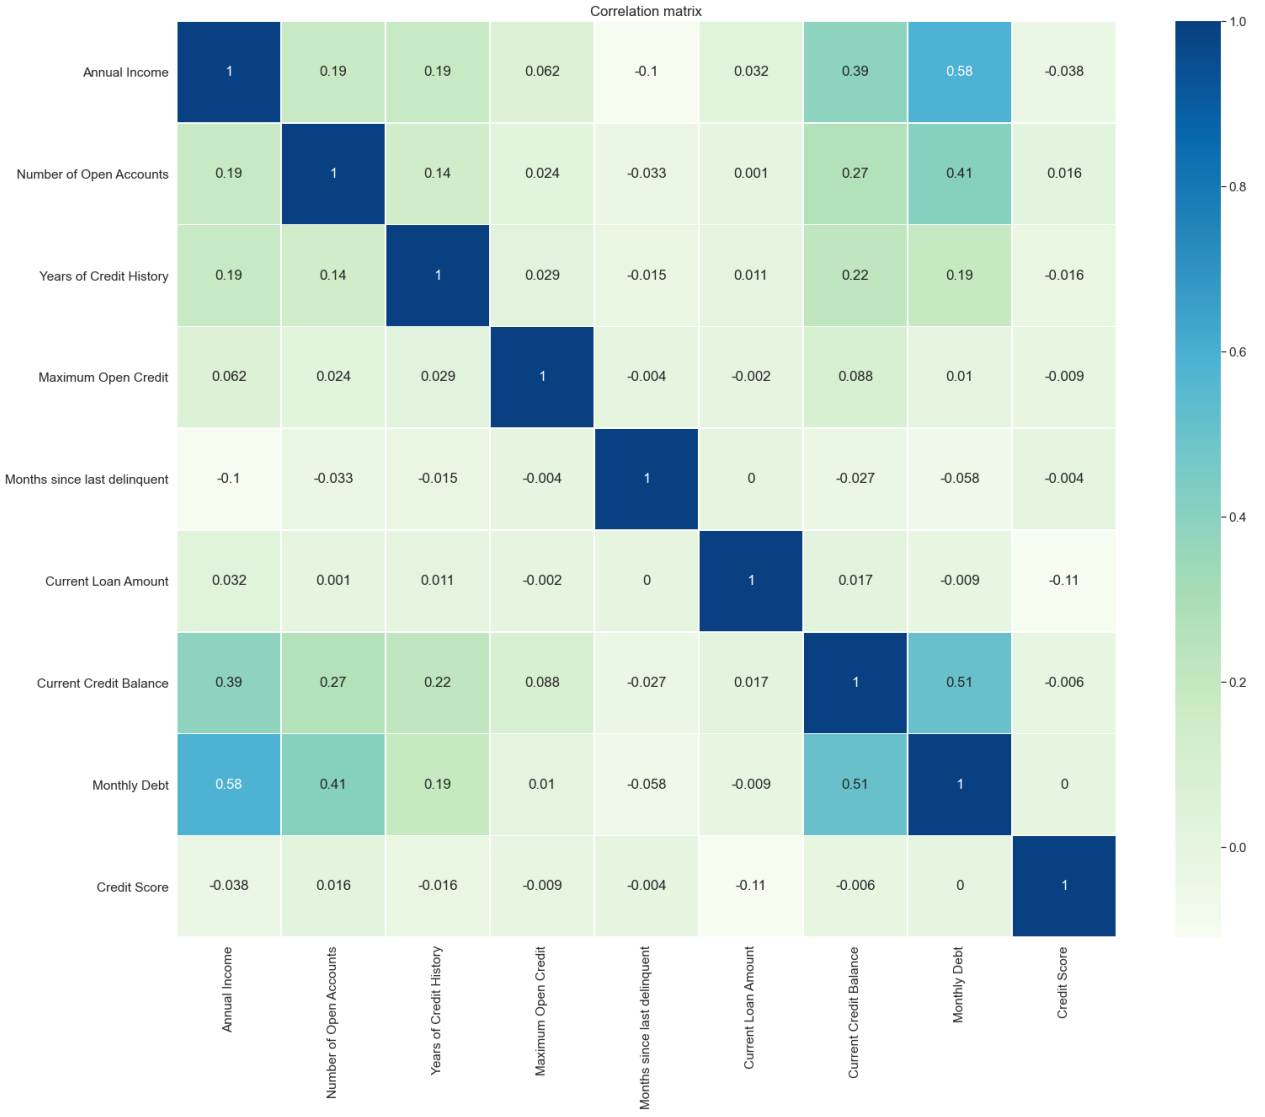

1. Наблюдается сильная положительная корреляция **(0.78)** между полями **'Current Loan Amount'** и **'Maximum Open Credit'**. Поэтому исключим из рассмотрения поле **'Maximum Open Credit'**
2. Наблюдается средняя положительная корреляция **(0.39)** между полями **'Number of Open Accounts'** и **'Maximum Open Credit'**.
3. Наблюдается средняя положительная корреляция **(0.37)** между полями **'Annual Income'** и **'Current Credit Balance'**.
4. Корреляции между **'Credit Score'** и **'Current Loan Amount'** слабая, отрицательная (**-0.084**).

B [ ]:
```

```

Приведение типов

B [37]:
```
for colname in ['Tax Liens', 'Number of Credit Problems', 'Bankruptcies']:
    df_train[colname] = df_train[colname].astype(str)
```

Обзор категориальных (номинативных, порядковых) признаков

Категориальные данные:

1. 'Home Ownership' (порядковые данные)

- Have Mortgage (ипотека) 12
- Own Home 647
- Rent 3204
- Home Mortgage 3637
- -
- Name: Home Ownership, dtype: int64

3. 'Years in current job' (порядковые данные)

- 9 years 259
- 8 years 339
- 7 years 396
- 6 years 426
- 4 years 469
- 1 year 504
- 5 years 516
- < 1 year 563
- 3 years 620
- 2 years 705
- 10+ years 2332
- -
- Name: Years in current job, dtype: int64

4. 'Tax Liens' - налоговые обременения (порядковые данные)

- 7.0 1
- 5.0 2
- 6.0 2
- 4.0 6
- 3.0 10
- 2.0 30
- 1.0 83
- 0.0 7366
- -
- Name: Tax Liens, dtype: int64

8. 'Number of Credit Problems' - количество проблем с кредитом (порядковые данные)

- 7.0 1
- 6.0 4
- 5.0 7
- 4.0 9
- 3.0 35
- 2.0 93
- 1.0 882
- 0.0 6469
- -
- Name: Number of Credit Problems, dtype: int64

10. 'Bankruptcies' - банкротства (порядковые данные)

- 4.0 2
- 3.0 7
- 2.0 31
- 1.0 786
- 0.0 6660
- -
- Name: Bankruptcies, dtype: int64

11. Purpose - цель кредита (порядковые данные)

- renewable energy (Возобновляемая энергия) 2
- vacation (отпуск) 8
- educational expenses (расходы на образование) 10
- moving (переезд?) 11
- wedding (свадьба) 15
- small business 26
- buy house 34
- take a trip (отправиться в путешествие) 37
- major purchase (крупная покупка) 40
- medical bills (Медицинские счета) 71
- buy a car 96
- business loan (бизнес-кредит) 129
- home improvements (Домашние улучшения) 412
- other 665
- debt consolidation (консолидация долгов) 5944
- -
- Name: Purpose, dtype: int64

12. Term - срок кредита (номинативные данные)

- Long Term 1944
- Short Term 5556
-
- Name: Term, dtype: int64

В [38]:
```
df_train.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7500 entries, 0 to 7499
Data columns (total 17 columns):
 #   Column                         Non-Null Count  Dtype
---  ------                         --------------  -----
 0   Home Ownership                 7500 non-null   object
 1   Annual Income                  5943 non-null   float64
 2   Years in current job           7129 non-null   object
 3   Tax Liens                      7500 non-null   object
 4   Number of Open Accounts        7500 non-null   float64
 5   Years of Credit History        7500 non-null   float64
 6   Maximum Open Credit            7500 non-null   float64
 7   Number of Credit Problems      7500 non-null   object
 8   Months since last delinquent   3419 non-null   float64
 9   Bankruptcies                   7500 non-null   object
 10  Purpose                        7500 non-null   object
 11  Term                           7500 non-null   object
 12  Current Loan Amount            7500 non-null   float64
 13  Current Credit Balance         7500 non-null   float64
 14  Monthly Debt                   7500 non-null   float64
 15  Credit Score                   5943 non-null   float64
 16  Credit Default                 7500 non-null   int64
dtypes: float64(9), int64(1), object(7)
memory usage: 996.2+ KB
```

В [39]:
```
df_train.select_dtypes(include='object').columns
```

Out[39]:
```
Index(['Home Ownership', 'Years in current job', 'Tax Liens',
       'Number of Credit Problems', 'Bankruptcies', 'Purpose', 'Term'],
      dtype='object')
```

Обзор значений категориальных признаков

B [40]:
```
for cat_colname in df_train.select_dtypes(include='object').columns:
    print(str(cat_colname) + '\n\n' + str(df_train[cat_colname].value_counts()) + '\n' + '*

# Bankruptcies имеет странное значение 'nan' (14 значений), нужно заменить на 0
```

```
Home Ownership

Home Mortgage    3637
Rent             3204
Own Home          647
Have Mortgage      12
Name: Home Ownership, dtype: int64
**********************************************************************************
**********

Years in current job

10+ years    2332
2 years       705
3 years       620
< 1 year      563
5 years       516
1 year        504
4 years       469
6 years       426
7 years       396
8 years       339
9 years       259
Name: Years in current job, dtype: int64
**********************************************************************************
**********

Tax Liens

0.0    7366
1.0      83
2.0      30
3.0      10
4.0       6
6.0       2
5.0       2
7.0       1
Name: Tax Liens, dtype: int64
**********************************************************************************
**********

Number of Credit Problems

0.0    6469
1.0     882
2.0      93
3.0      35
4.0       9
5.0       7
6.0       4
7.0       1
Name: Number of Credit Problems, dtype: int64
**********************************************************************************
**********

Bankruptcies

0.0    6660
```

```
1.0     786
2.0      31
nan      14
3.0       7
4.0       2
Name: Bankruptcies, dtype: int64
**********
**********

Purpose

debt consolidation      5944
other                    665
home improvements        412
business loan            129
buy a car                 96
medical bills             71
major purchase            40
take a trip               37
buy house                 34
small business            26
wedding                   15
moving                    11
educational expenses      10
vacation                   8
renewable energy           2
Name: Purpose, dtype: int64
**********
**********

Term

Short Term    5556
Long Term     1944
Name: Term, dtype: int64
**********
**********
```

2. Обработка выбросов

2. **Annual Income** - годовой доход

- **Считаем выбросами Annual Income > 4 000 000 (91 значения) и Annual Income < 164597**
- Считаем выбросами Annual Income > 5 000 000 (44 значения) и Annual Income < 164597

6. **Years of Credit History** - количество лет кредитной истории

- **Считаем выбросами Years of Credit History > 40 (83 значения)**
- Считаем выбросами Years of Credit History > 50 (8 значения)

7. **Maximum Open Credit** - наибольший открытый кредит

- **Считаем выбросами значения 'Maximum Open Credit' > 4 000 000 (64 значений) 'Maximum Open Credit' < 50 000 (125 значений)**
- Считаем выбросами значения 'Maximum Open Credit' > 2 000 000 (249 значений) 'Maximum Open Credit' < 50 000 (125 значений)

9. **Months since last delinquent** - количество месяцев с последней просрочки платежа

- Более 3500 null значений - удаляем столбец

- Считаем выбросами Months since last delinquent > 83 (5 значений)

13. **Current Loan Amount** - текущая сумма кредита

- Набор данных надо разбивать на два по сумме кредита: 1 - [0, ..., 2 * 10^7], 2 - [85 * 10^7, ..., 1 * 10^8]
- Проверить кооряляцию с Credit Score - Кредитный рейтинг

14. **Current Credit Balance** - текущий кредитный баланс

- **Считаем выбросами значения 'Current Credit Balance' > 1300000 (106 значений)**
- Считаем выбросами значения 'Current Credit Balance' > 2500000 (21 значений)

15. **Monthly Debt** - ежемесячный долг

- **Считаем выбросами значения 'Monthly Debt' > 55 000 (98 значений)**
- Считаем выбросами значения 'Monthly Debt' > 80 000 (17 значений)

16. **Credit Score** - Кредитный рейтинг?

- **Считаем выбросами значения 'Monthly Debt' < 585 и 'Monthly Debt' > 7510**
- Набор данных надо разбивать на два по Кредитному рейтингу: 1 - [585, ...,800], 2 - [6500, ..., 7500]
- Проверить кооряляцию с Current Loan Amount - текущая сумма кредита

3. Обработка пропусков

B [41]:
```
df_train.isnull()
#df_example.notnull()
```

Out[41]:

	Home Ownership	Annual Income	Years in current job	Tax Liens	Number of Open Accounts	Years of Credit History	Maximum Open Credit	Number of Credit Problems	Months since last delinquent	Bankruptcies	P
0	False	False	True	False	False	False	False	False	True	False	
1	False	False	False	False	False	False	False	False	True	False	
2	False	False	False	False	False	False	False	False	True	False	
3	False	False	False	False	False	False	False	False	True	False	
4	False	False	False	False	False	False	False	False	True	False	
...	...	...	...	...	...	...	...	...	...	...	
7495	False	False	False	False	False	False	False	False	True	False	
7496	False	False	False	False	False	False	False	False	False	False	
7497	False	False	False	False	False	False	False	False	True	False	
7498	False	True	True	False	False	False	False	False	True	False	
7499	False	True	False	False	False	False	False	False	True	False	

7500 rows × 17 columns

В [42]:
```
#Len(df_train) - df_train.count()
df_train.isna().sum()  # просматриваем пропуски
```

Out[42]:
```
Home Ownership                   0
Annual Income                 1557
Years in current job           371
Tax Liens                        0
Number of Open Accounts          0
Years of Credit History          0
Maximum Open Credit              0
Number of Credit Problems        0
Months since last delinquent  4081
Bankruptcies                     0
Purpose                          0
Term                             0
Current Loan Amount              0
Current Credit Balance           0
Monthly Debt                     0
Credit Score                  1557
Credit Default                   0
dtype: int64
```

Нулевые значения имеются в столбцах **"Annual Income", "Years in current job", "Months since last delinquent"** и **"Credit Score"**

В [43]:
```
#df_train.info()
#df_train = df_train.fillna(median)
```

Years in current job - количество лет на текущем месте работы

В [44]:
```
# количество пропусков
df_train['Years in current job'].isnull().sum()
```

Out[44]:
```
371
```

В [45]:
```
df_train[cat_colname] = df_train[cat_colname].replace(to_replace = np.nan, value = 'неизвес
```

В [46]:
```
cat_colname = 'Years in current job'
print(str(cat_colname) + '\n\n' + str(df_train[cat_colname].value_counts()) + '\n' + '*' *
```

```
Years in current job

10+ years    2332
2 years       705
3 years       620
< 1 year      563
5 years       516
1 year        504
4 years       469
6 years       426
7 years       396
8 years       339
9 years       259
Name: Years in current job, dtype: int64
**************************************************************************************
**********
```

В [47]:
```
df_train.isna().sum()  # просматриваем пропуски
```

Out[47]:
```
Home Ownership                    0
Annual Income                  1557
Years in current job            371
Tax Liens                         0
Number of Open Accounts           0
Years of Credit History           0
Maximum Open Credit               0
Number of Credit Problems         0
Months since last delinquent    4081
Bankruptcies                      0
Purpose                           0
Term                              0
Current Loan Amount               0
Current Credit Balance            0
Monthly Debt                      0
Credit Score                   1557
Credit Default                    0
dtype: int64
```

Очистка данных

Класс с подготовкой данных

В [48]:
```
# Считаем выбросами Годовой доход 'Annual Income' > 4 000 000 (91 значения) и Annual Income
# Считаем выбросами Количество лет кредитной истории 'Years of Credit History' > 40 (83 зна
# Считаем выбросами Наибольший открытый кредит 'Maximum Open Credit' > 4 000 000 (64 значен
# и 'Maximum Open Credit' < 50 000 (125 значений)
# Считаем выбросами Количество месяцев с последней просрочки платежа Months since last deli
# Считаем выбросами Текущий кредитный баланс 'Current Credit Balance' > 1300000 (106 значен
# Считаем выбросами Ежемесячный долг 'Monthly Debt' > 55 000 (98 значений)
# Считаем выбросами Кредитный рейтинг 'Monthly Debt' < 585 и 'Monthly Debt' > 7510
```

В [49]:
```
class DataPipeLine:
    """Подготовка исходных данных"""

    def __init__(self):
        """Параметры класса:
           Константы для обработки выбрасов"""

        self.medians = None
        self.modes = None

        self.AnnualIncome_min = 165000
        self.AnnualIncome_max = 4000000

        self.YearsofCreditHistory_max = 40

        self.MaximumOpenCredit_min = 50000
        self.MaximumOpenCredit_max = 4000000

        self.MonthsSinceLastDelinquent_max = 83
        self.CurrentLoanAmount_max = 1000000
        self.CurrentCreditBalance_max = 1300000
        self.MonthlyDebt_max = 55000

        self.MonthlyDebt_min = 585
        self.MonthlyDebt_max = 7510


    def fit(self, df):
        """Сохранение статистик"""

        # Расчёт медиан
        self.medians = df_train[['Annual Income', 'Credit Score']].median()
        df = df_train.loc[df_train['Current Loan Amount'] < self.CurrentLoanAmount_max, ['C
        self.modes = df[['Current Loan Amount']].median()


    def transform(self, df):
        """Трансформация данных"""

        # 1. Обработка пропусков
        #df_train = df_train.fillna(median)

        df[['Annual Income', 'Credit Score']] = df[['Annual Income', 'Credit Score']].filln

        # Months since last delinquent
        # 3581 пропущенное значение из 7500 - удаляем
        if 'Months since last delinquent' in df.columns:
            # df = df.drop(['Months since last delinquent'], axis=1)
            df.drop('Months since last delinquent', axis=1, inplace=True)

        # Years in current job
        cat_colname = 'Years in current job'
        df[cat_colname] = df[cat_colname].replace(to_replace = np.nan, value = 'неизвестно'

        # 2. Выбросы (outliers)

        # Annual Income - годовой доход
        df.loc[df['Annual Income'] < self.AnnualIncome_min, 'Annual Income'] = self.AnnualI
        df.loc[df['Annual Income'] >= self.AnnualIncome_max, 'Annual Income'] = self.Annual

        # Years of Credit History - Количество лет кредитной истории
        df.loc[df['Years of Credit History'] >= self.YearsofCreditHistory_max, 'Years of Cr
```

```
        # Maximum Open Credit - наибольший открытый кредит
        df.loc[df['Maximum Open Credit'] < self.MaximumOpenCredit_min, 'Maximum Open Credit
        df.loc[df['Maximum Open Credit'] >= self.MaximumOpenCredit_max, 'Maximum Open Credi

        # Current Loan Amount - текущая сумма кредита
        df.loc[df['Current Loan Amount'] >= self.CurrentLoanAmount_max, 'Current Loan Amoun

        # Current Credit Balance - текущий кредитный баланс
        df.loc[df['Current Credit Balance'] >= self.CurrentCreditBalance_max, 'Current Cred

        # Monthly Debt - Ежемесячный долг
        df.loc[df['Monthly Debt'] >= self.MonthlyDebt_max, 'Monthly Debt'] = self.MonthlyDe

        # Monthly Debt - Кредитный рейтинг
        df.loc[df['Monthly Debt'] < self.MonthlyDebt_min, 'Monthly Debt'] = self.MonthlyDeb
        df.loc[df['Monthly Debt'] >= self.MonthlyDebt_max, 'Monthly Debt'] = self.MonthlyDe

        # 3. Обработка категорий
        colname = 'Bankruptcies'
        df[colname] = df[colname].replace(to_replace = 'nan', value = '0.0')
        # (создание дами-переменных)
        #df = pd.concat([df, pd.get_dummies(df['Tax Liens'], prefix='Tax Liens', dtype='int
        #df = pd.concat([df, pd.get_dummies(df['Number of Credit Problems'], prefix='Number
        #df = pd.concat([df, pd.get_dummies(df['Bankruptcies'], prefix='Bankruptcies', dtyp

        return df


    def features(self, df):
        """4. Feature engineering
              Генерация новых фич"""

        # 1. Home Ownership - домовладение
        cat_colname = 'Home_Ownership_int'

        df[cat_colname] = df['Home Ownership']
        df.loc[df[cat_colname] == 'Have Mortgage', cat_colname] = 0
        df.loc[df[cat_colname] == 'Own Home', cat_colname] = 1
        df.loc[df[cat_colname] == 'Rent', cat_colname] = 2
        df.loc[df[cat_colname] == 'Home Mortgage', cat_colname] = 3

        # 3. 'Years in current job' (порядковые данные)
        cat_colname = 'Years_in_current_job_int'

        df[cat_colname] = df['Years in current job']
        df.loc[df[cat_colname] == '< 1 year', cat_colname] = 0
        df.loc[df[cat_colname] == '1 year', cat_colname] = 1
        df.loc[df[cat_colname] == '2 years', cat_colname] = 2
        df.loc[df[cat_colname] == '3 years', cat_colname] = 3
        df.loc[df[cat_colname] == '4 years', cat_colname] = 4
        df.loc[df[cat_colname] == '5 years', cat_colname] = 5
        df.loc[df[cat_colname] == '6 years', cat_colname] = 6
        df.loc[df[cat_colname] == '7 years', cat_colname] = 7
        df.loc[df[cat_colname] == '8 years', cat_colname] = 8
        df.loc[df[cat_colname] == '9 years', cat_colname] = 9
        df.loc[df[cat_colname] == '10+ years', cat_colname] = 10
        df.loc[df[cat_colname] == 'неизвестно', cat_colname] = 11

        # 11. Purpose - цель кредита (порядковые данные)
        cat_colname = 'Purpose_int'

        df[cat_colname] = df['Purpose']
        df.loc[df[cat_colname] == 'renewable energy', cat_colname] = 0
        df.loc[df[cat_colname] == 'vacation', cat_colname] = 1
```

```
        df.loc[df[cat_colname] == 'educational expenses', cat_colname] = 2
        df.loc[df[cat_colname] == 'moving', cat_colname] = 3
        df.loc[df[cat_colname] == 'wedding', cat_colname] = 4
        df.loc[df[cat_colname] == 'small business', cat_colname] = 5
        df.loc[df[cat_colname] == 'buy house', cat_colname] = 6
        df.loc[df[cat_colname] == 'take a trip', cat_colname] = 7
        df.loc[df[cat_colname] == 'major purchase', cat_colname] = 8
        df.loc[df[cat_colname] == 'medical bills', cat_colname] = 9
        df.loc[df[cat_colname] == 'buy a car', cat_colname] = 10
        df.loc[df[cat_colname] == 'business loan', cat_colname] = 11
        df.loc[df[cat_colname] == 'home improvements', cat_colname] = 12
        df.loc[df[cat_colname] == 'other', cat_colname] = 13
        df.loc[df[cat_colname] == 'debt consolidation', cat_colname] = 14

        # 12. Term - срок кредита (номинативные данные)
        cat_colname = 'Term_int'

        df[cat_colname] = df['Term']
        df.loc[df[cat_colname] == 'Long Term', cat_colname] = 0
        df.loc[df[cat_colname] == 'Short Term', cat_colname] = 1


        numbers = ['0.0', '1.0', '2.0', '3.0', '4.0', '5.0', '6.0', '7.0', '8.0', '9.0']
        numbers_int = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]

        # Добавление признаков
        colnames_new = ['Tax_Liens_int', 'Number_of_Credit_Problems_int', 'Bankruptcies_int
        colnames = ['Tax Liens', 'Number of Credit Problems', 'Bankruptcies']

        for i in range(len(colnames_new)):
            df[colnames_new[i]] = df[colnames[i]]
            for j in range(len(numbers)):
                df.loc[df[colnames_new[i]] == numbers[j], colnames_new[i]] = numbers_int[j]

        # Обработка категорий
        for colname in ['Home_Ownership_int', 'Years_in_current_job_int', 'Purpose_int', 'T
             df_train[colname] = df_train[colname].astype('int8')
        for colname in colnames_new:
             df_train[colname] = df_train[colname].astype('int8')

        # 16. Credit Score - Кредитный рейтинг
        df['CreditScore_small'] = df['Credit Score']
        df['CreditScore_large'] = df['Credit Score']

        df.loc[df['Credit Score'] > 2000, 'CreditScore_small'] = 0.0
        df.loc[df['Credit Score'] < 600, 'CreditScore_small'] = 0.0

        df.loc[df['Credit Score'] < 3000, 'CreditScore_large'] =  0.0
        df.loc[df['Credit Score'] > 9000, 'CreditScore_large'] = 0.0

        return df
```

Инициализируем класс

В [50]:
```
data_pl = DataPipeLine()

# тренировочные данные
data_pl.fit(df_train)

df = data_pl.transform(df_train)
```

В [51]:
```
df = data_pl.features(df_train)
```

В [52]:
```
#df.columns
#df.describe()
df.info()  # Рассмотрим типы признаков
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7500 entries, 0 to 7499
Data columns (total 25 columns):
 #   Column                         Non-Null Count  Dtype
---  ------                         --------------  -----
 0   Home Ownership                 7500 non-null   object
 1   Annual Income                  7500 non-null   float64
 2   Years in current job           7500 non-null   object
 3   Tax Liens                      7500 non-null   object
 4   Number of Open Accounts        7500 non-null   float64
 5   Years of Credit History        7500 non-null   float64
 6   Maximum Open Credit            7500 non-null   float64
 7   Number of Credit Problems      7500 non-null   object
 8   Bankruptcies                   7500 non-null   object
 9   Purpose                        7500 non-null   object
 10  Term                           7500 non-null   object
 11  Current Loan Amount            7500 non-null   float64
 12  Current Credit Balance         7500 non-null   float64
 13  Monthly Debt                   7500 non-null   float64
 14  Credit Score                   7500 non-null   float64
 15  Credit Default                 7500 non-null   int64
 16  Home_Ownership_int             7500 non-null   int8
 17  Years_in_current_job_int       7500 non-null   int8
 18  Purpose_int                    7500 non-null   int8
 19  Term_int                       7500 non-null   int8
 20  Tax_Liens_int                  7500 non-null   int8
 21  Number_of_Credit_Problems_int  7500 non-null   int8
 22  Bankruptcies_int               7500 non-null   int8
 23  CreditScore_small              7500 non-null   float64
 24  CreditScore_large              7500 non-null   float64
dtypes: float64(10), int64(1), int8(7), object(7)
memory usage: 1.1+ MB
```

B [53]:
```
colname = 'Bankruptcies'
df[colname] = df[colname].replace(to_replace = 'nan', value = '0.0')

#for cat_colname in df.select_dtypes(include='object').columns:
for cat_colname in df.select_dtypes(include='int8').columns:
    print(str(cat_colname) + '\n\n' + str(df[cat_colname].value_counts()) + '\n' + '*' * 10
```

```
Home_Ownership_int

3    3637
2    3204
1     647
0      12
Name: Home_Ownership_int, dtype: int64
**********
**********

Years_in_current_job_int

10    2332
2      705
3      620
0      563
5      516
1      504
4      469
6      426
7      396
11     371
8      339
9      259
Name: Years_in_current_job_int, dtype: int64
**********
**********

Purpose_int

14    5944
13     665
12     412
11     129
10      96
9       71
8       40
7       37
6       34
5       26
4       15
3       11
2       10
1        8
0        2
Name: Purpose_int, dtype: int64
**********
**********

Term_int

1    5556
0    1944
Name: Term_int, dtype: int64
**********
**********
```

```
Tax_Liens_int

0    7366
1      83
2      30
3      10
4       6
6       2
5       2
7       1
Name: Tax_Liens_int, dtype: int64
********************************************************************************
**********

Number_of_Credit_Problems_int

0    6469
1     882
2      93
3      35
4       9
5       7
6       4
7       1
Name: Number_of_Credit_Problems_int, dtype: int64
********************************************************************************
**********

Bankruptcies_int

0    6674
1     786
2      31
3       7
4       2
Name: Bankruptcies_int, dtype: int64
********************************************************************************
**********
```

B [54]:
```
feature_name = 'CreditScore_small'
feature_value_max = 1000
feature_value_min = 600
data_type = 0
#plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)
plot_feature(feature_name, df, feature_value_max, feature_value_min, data_type)
```

```
feature_name = CreditScore_small
feature_value_max = 1000
feature_value_min = 600
_____________________________________________________

Количество
_____________________________________________________
629.0       1
604.0       1
602.0       1
619.0       1
620.0       1
          ...
748.0     157
747.0     168
740.0     169
0.0       414
731.0    1651
Name: CreditScore_small, Length: 148, dtype: int64
_____________________________________________________

Отсортированные записи
_____________________________________________________
3749      0.0
325       0.0
1862      0.0
5899      0.0
1875      0.0
         ...
1849    751.0
873     751.0
1957    751.0
5795    751.0
6584    751.0
Name: CreditScore_small, Length: 7500, dtype: float64
_____________________________________________________

Первичный датасет

Мода датасета: 731.0
Медиана датасета: 731.0
Среднее значение датасета: 683.2993333333334
Максимальное значение датасета: 751.0
Минимальное значение датасета: 0.0
_____________________________________________________

Количество записей в датасете: 7500
Количество записей в датасете < 600: 414
Количество записей в датасете > 1000: 0
_____________________________________________________

Обработанный датасет

Мода датасета: 731.0
Медиана датасета: 731.0
Среднее значение датасета: 723.2211402766018
```

```
Максимальное значение датасета: 751.0
Минимальное значение датасета: 601.0
```

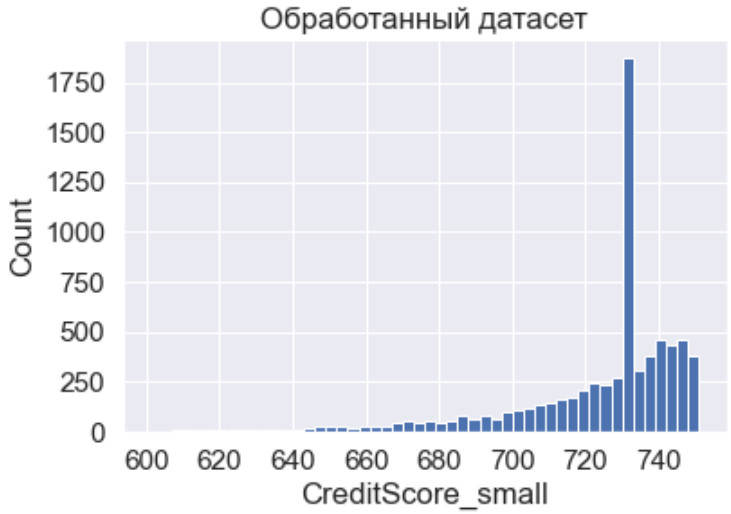

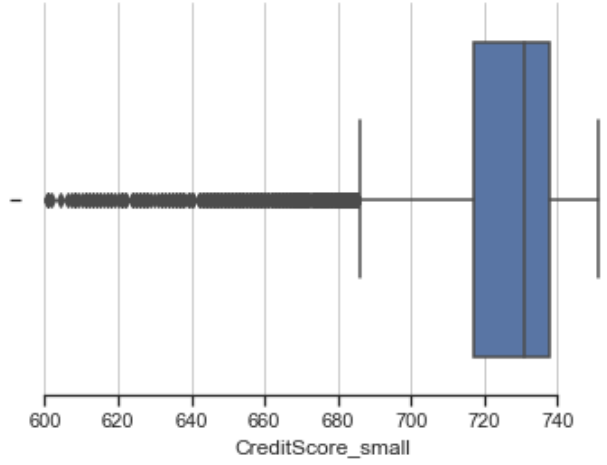

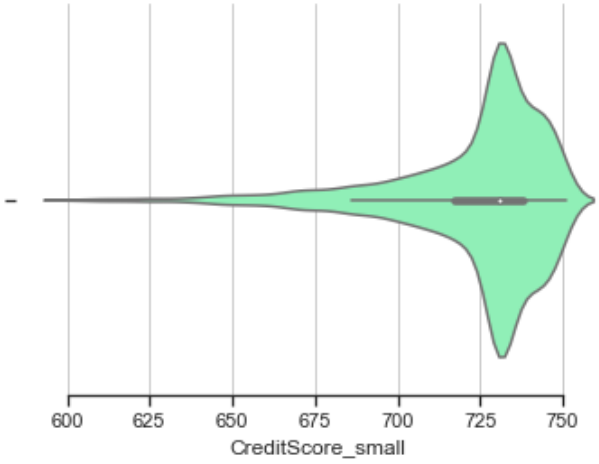
600
625
650
675
700
725
750
CreditScore_small

B [55]:
```
feature_name = 'CreditScore_large'
feature_value_max = 10000
feature_value_min = 3000
data_type = 0
#plot_feature(feature_name, df_train, feature_value_max, feature_value_min, data_type)
plot_feature(feature_name, df, feature_value_max, feature_value_min, data_type)
```

```
feature_name = CreditScore_large
feature_value_max = 10000
feature_value_min = 3000
_____________________________________________________

Количество
_____________________________________________________
6670.0       1
6710.0       1
6170.0       1
6770.0       1
6570.0       1
           ...
7370.0      12
7330.0      13
7300.0      13
7400.0      15
0.0       7100
Name: CreditScore_large, Length: 111, dtype: int64
_____________________________________________________

Отсортированные записи
_____________________________________________________
0          0.0
4922       0.0
4921       0.0
4920       0.0
4919       0.0
          ...
3063    7490.0
355     7500.0
2408    7500.0
2213    7510.0
3688    7510.0
Name: CreditScore_large, Length: 7500, dtype: float64
_____________________________________________________

Первичный датасет

Мода датасета: 0.0
Медиана датасета: 0.0
Среднее значение датасета: 379.472
Максимальное значение датасета: 7510.0
Минимальное значение датасета: 0.0
_____________________________________________________

Количество записей в датасете: 7500
Количество записей в датасете < 3000: 7100
Количество записей в датасете > 10000: 0
_____________________________________________________

Обработанный датасет

Мода датасета: 7400.0
Медиана датасета: 7190.0
Среднее значение датасета: 7115.1
```

```
Максимальное значение датасета: 7510.0
Минимальное значение датасета: 6060.0
```

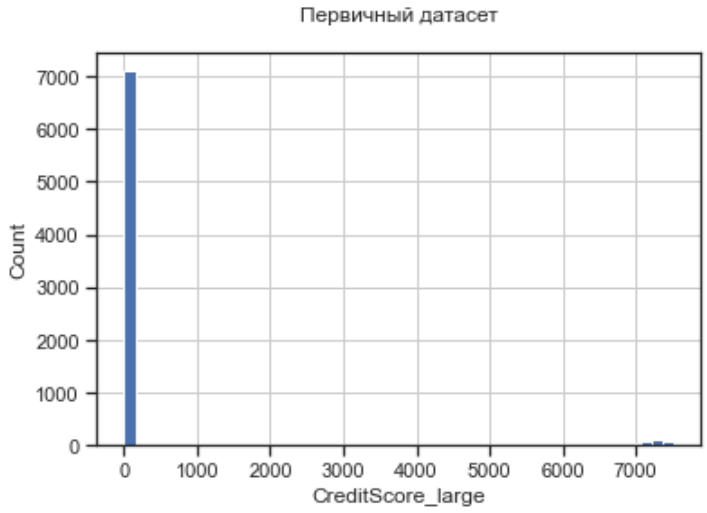

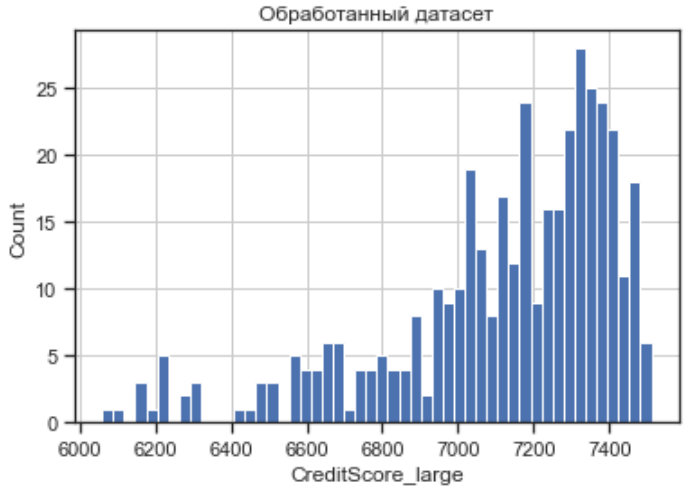

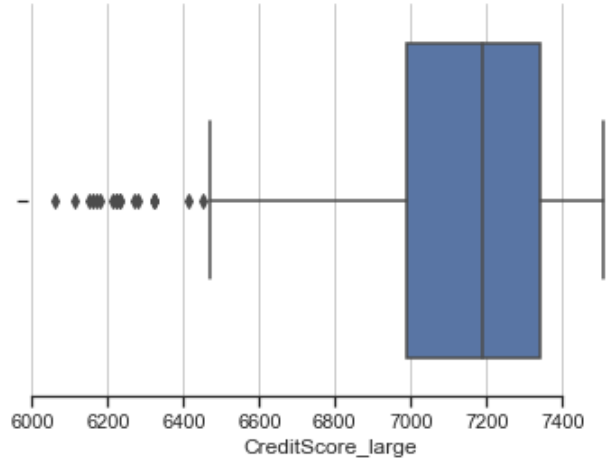

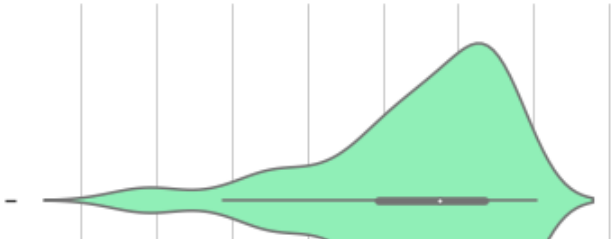

4. Анализ данных

см. выше

5. Отбор признаков

В [56]:
```
df.columns.tolist()
```

Out[56]:
```
['Home Ownership',
 'Annual Income',
 'Years in current job',
 'Tax Liens',
 'Number of Open Accounts',
 'Years of Credit History',
 'Maximum Open Credit',
 'Number of Credit Problems',
 'Bankruptcies',
 'Purpose',
 'Term',
 'Current Loan Amount',
 'Current Credit Balance',
 'Monthly Debt',
 'Credit Score',
 'Credit Default',
 'Home_Ownership_int',
 'Years_in_current_job_int',
 'Purpose_int',
 'Term_int',
 'Tax_Liens_int',
 'Number_of_Credit_Problems_int',
 'Bankruptcies_int',
 'CreditScore_small',
 'CreditScore_large']
```

B [57]:
```
df.head(2)
```

Out[57]:

	Home Ownership	Annual Income	Years in current job	Tax Liens	Number of Open Accounts	Years of Credit History	Maximum Open Credit	Number of Credit Problems	Bankruptcies	Purpose
0	Own Home	482087.0	неизвестно	0.0	11.0	26.3	685960.0	1.0	1.0	deb consolidatior
1	Own Home	1025487.0	10+ years	0.0	15.0	15.3	1181730.0	0.0	0.0	deb consolidatior

2 rows × 25 columns

B [58]:
```
feature_names = [#'Home Ownership',
                 'Annual Income',
                 #'Years in current job',
                 #'Tax Liens',
                 'Number of Open Accounts',
                 'Years of Credit History',
                 'Maximum Open Credit',
                 #'Number of Credit Problems',
                 #'Bankruptcies',
                 #'Purpose',
                 #'Term',
                 'Current Loan Amount',
                 'Current Credit Balance',
                 'Monthly Debt',
                 #'Credit Score',
                 #'Credit Default',
                 'Home_Ownership_int',
                 'Years_in_current_job_int',
                 'Purpose_int',
                 'Term_int',
                 'Tax_Liens_int',
                 'Number_of_Credit_Problems_int',
                 'Bankruptcies_int',
                 'CreditScore_small',
                 'CreditScore_large']

target_name = 'Credit Default'
```

B [59]:
```
TARGET_NAME = 'Credit Default'
BASE_FEATURE_NAMES = feature_names
BASE_FEATURE_NAMES
```

Out[59]:
```
['Annual Income',
 'Number of Open Accounts',
 'Years of Credit History',
 'Maximum Open Credit',
 'Current Loan Amount',
 'Current Credit Balance',
 'Monthly Debt',
 'Home_Ownership_int',
 'Years_in_current_job_int',
 'Purpose_int',
 'Term_int',
 'Tax_Liens_int',
 'Number_of_Credit_Problems_int',
 'Bankruptcies_int',
 'CreditScore_small',
 'CreditScore_large']
```

B [60]:
```
corr_with_target = df[BASE_FEATURE_NAMES + [TARGET_NAME]].corr().iloc[:-1, -1].sort_values(

plt.figure(figsize=(10, 8))

sns.barplot(x=corr_with_target.values, y=corr_with_target.index)

plt.title('Correlation with target variable')
plt.show()
```

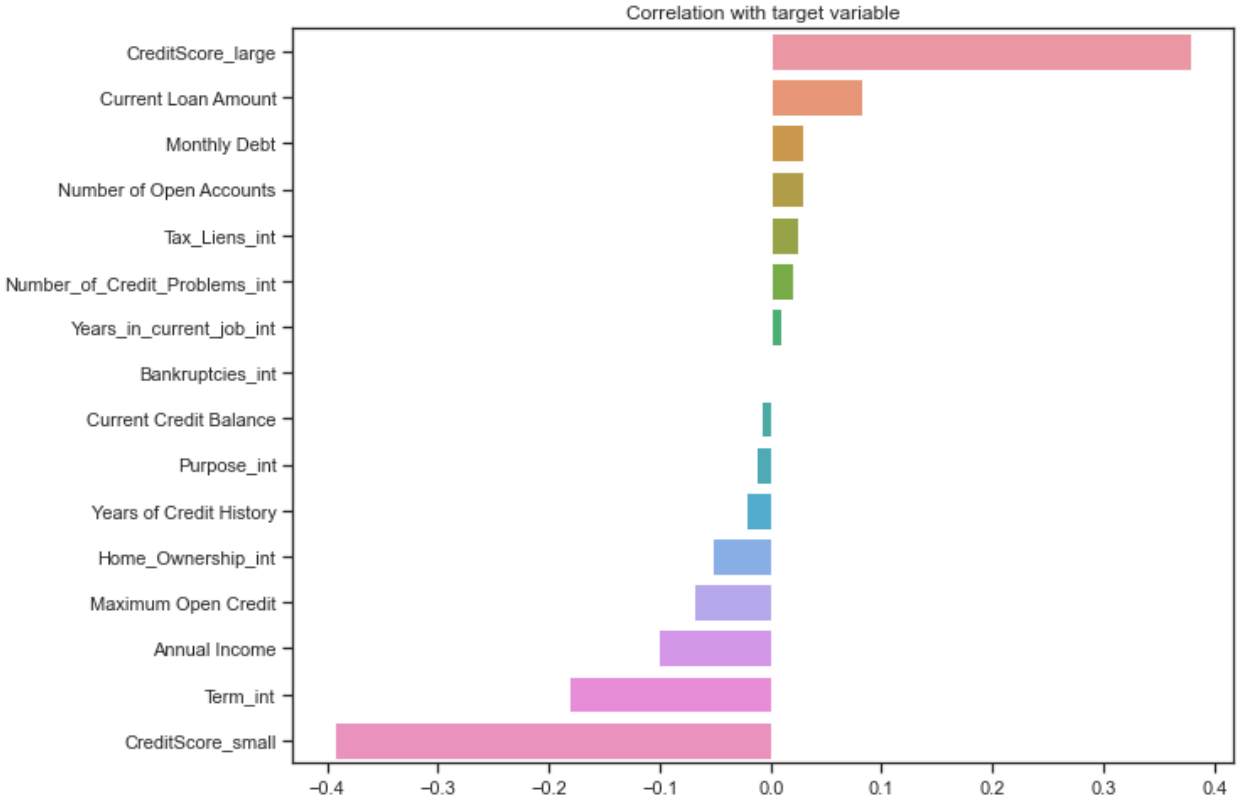

B [61]:
```
plt.figure(figsize = (25,20))

sns.set(font_scale=1.4)
sns.heatmap(df[BASE_FEATURE_NAMES].corr().round(3), annot=True, linewidths=.5, cmap='GnBu')

plt.title('Correlation matrix')
plt.show()
```

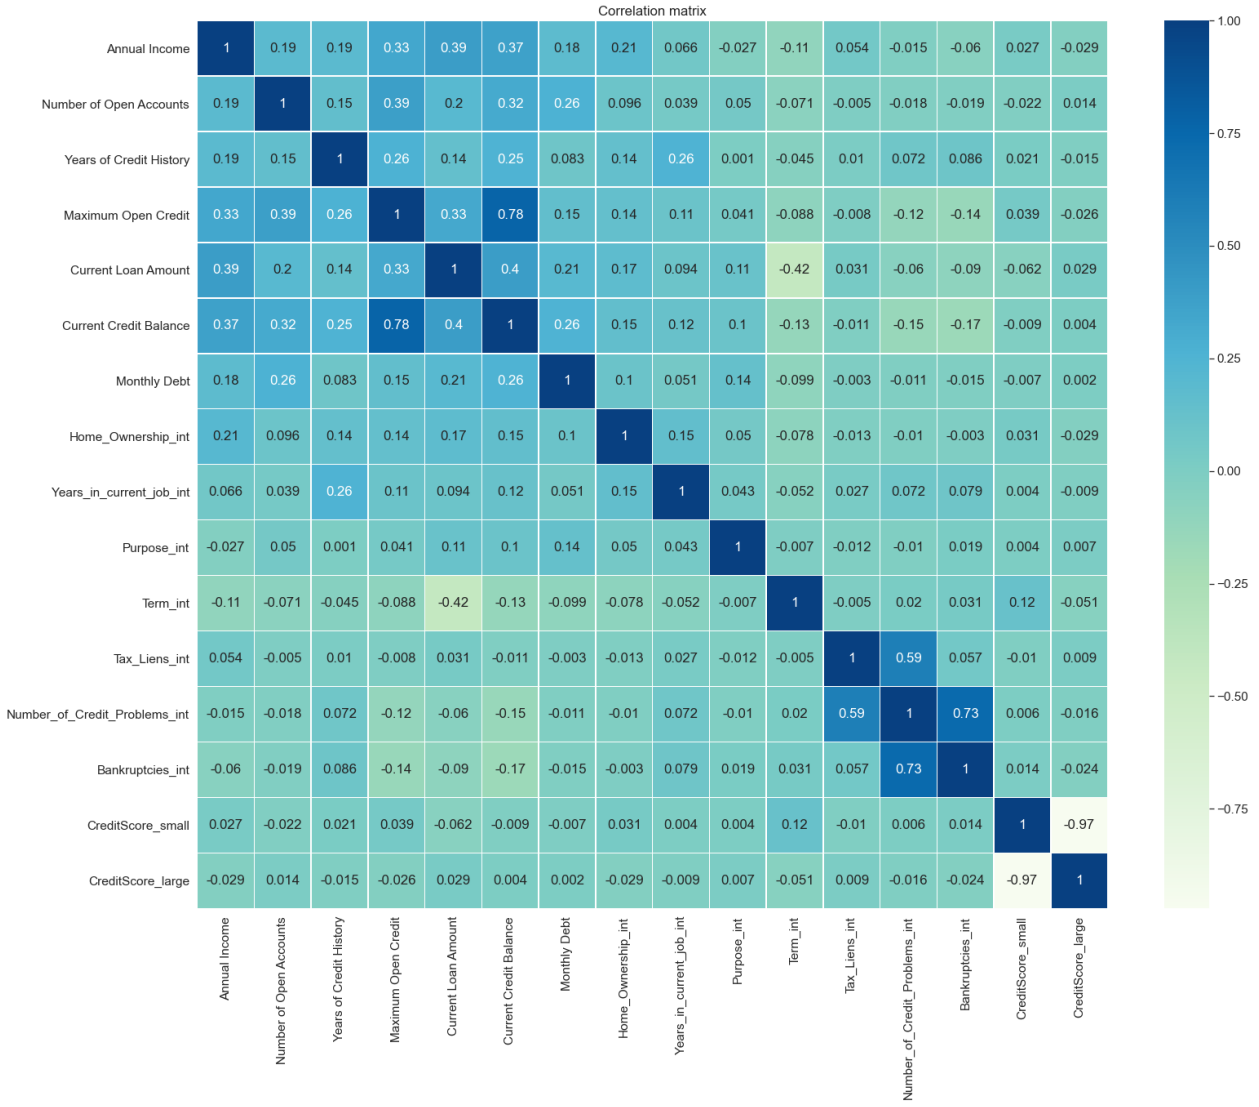

1. Наблюдается сильная положительная корреляция (**0.78**) между признаками **'Current Loan Amount'** и **'Maximum Open Credit'**. Но так ка **'Current Loan Amount'** слабо влияет на целевой показатель, данный признак можно исключить из анализа.
2. Наблюдается сильная положительная корреляция (**0.73**) между признаками **'Bankruptcies_int'** и **'Number_of_Credit_Problems_int'**. При этом **'Bankruptcies_int'** слабо влияет на целевой показатель, данный признак можно исключить из анализа.
3. Наблюдается средняя положительная корреляция (**0.59**) между признаками **'Number_of_Credit_Problems_int'** и **'Tax_Liens_int'**. При этом **'Number_of_Credit_Problems_int'** слабо влияет на целевой показатель. Но **'Number_of_Credit_Problems_int'** сильно связан с

признаком **'Bankruptcies_int'**, который мы исключили. Поэтому **'Number_of_Credit_Problems_int'** оставляем.

4. Наблюдается сильная отрицательная корреляция (**-0.97**) между признаками **'CreditScore_small'** и **'CreditScore_large'**. При этом оба признака сильно влияют на целевой показатель. Оставляем оба признака.

6. Балансировка классов
7. Подбор моделей, получение бейзлана
8. Выбор наилучшей модели, настройка гиперпараметров
9. Проверка качества, борьба с переобучением
10. Интерпретация результатов

Прогнозирование на тестовом датасете

1. Выполнить для тестового датасета те же этапы обработки и построниянияя признаков
2. Спрогнозировать целевую переменную, используя модель, построенную на обучающем датасете
3. Прогнозы должны быть для всех примеров из тестового датасета (для всех строк)
4. Соблюдать исходный порядок примеров из тестового датасета

```
В [ ]:
```